

ALGORITMA FACE RECOGNITION DENGAN ONE-SHOT QUERY UNTUK PENCARIAN FOTO OTOMATIS BERDASARKAN FOTO SELFIE

Laporan Tugas Akhir

Oleh

**Alfandito Rais Akbar
18222037**



**PROGRAM STUDI SISTEM DAN TEKNOLOGI INFORMASI
SEKOLAH TEKNIK ELEKTRO DAN INFORMATIKA
INSTITUT TEKNOLOGI BANDUNG**

Juli 2026

LEMBAR PENGESAHAN

ALGORITMA FACE RECOGNITION DENGAN ONE-SHOT QUERY UNTUK PENCARIAN FOTO OTOMATIS BERDASARKAN FOTO SELFIE

Laporan Tugas Akhir

Oleh

Alfandito Rais Akbar
18222037

Program Studi Sistem dan Teknologi Informasi
Sekolah Teknik Elektro dan Informatika
Institut Teknologi Bandung

Laporan Tugas Akhir ini telah disetujui dan disahkan
di Bandung, pada tanggal 3 Juli 2026

Pembimbing

Dr. Riza Satria Perdana, S.T, M.T.

NIP. 197006091995121002

PERNYATAAN ORISINALITAS

Saya yang bertanda tangan di bawah ini menyatakan dengan sesungguhnya bahwa:

1. Tugas Akhir ini adalah hasil karya saya sendiri yang dibuat dengan sebenar-benarnya sesuai dengan kaidah ilmiah dan etika akademik.
2. Semua sumber rujukan dan data yang saya gunakan dalam penyusunan laporan tugas akhir ini, baik yang berupa kutipan langsung maupun tidak langsung, telah saya cantumkan sumbernya dengan baik dan benar sesuai dengan ketentuan penulisan laporan tugas akhir.
3. Isi laporan ini belum pernah diajukan pada program pendidikan di institusi mana pun.

Apabila di kemudian hari terbukti bahwa laporan ini melanggar hal-hal di atas, saya bersedia menerima sanksi sesuai dengan peraturan yang berlaku di Institut Teknologi Bandung.

Bandung, 3 Juli 2026

Alfandito Rais Akbar

NIM: 18222037

PERNYATAAN PENGGUNAAN AI

Saya yang bertanda tangan di bawah ini menyatakan bahwa dalam penulisan dokumen Tugas Akhir ini, saya menggunakan alat bantu kecerdasan artifisial (AI) untuk beberapa aspek tertentu di dalam proses penulisan, seperti yang tercantum dalam tabel berikut.

No.	Jenis	Alat Bantu	Tingkat	Tempat
1	Memeriksa ejaan dan tata bahasa	Grammarly	Tinggi	Semua bab
2	Pembuatan teks	Microsoft Copilot	Sedang	Bab II hal. 15
3	Pembuatan grafik, gambar, atau ilustrasi	Tidak ada	Tidak ada	Tidak ada
4	Pencarian informasi atau referensi	...	...	...
5	Penyusunan bahan diskusi	...	...	...
6	Penyusunan kode program	...	...	...
7	Penyusunan formula atau perhitungan matematis	...	...	...
8	Penyusunan konsep desain atau algoritma	...	...	...
9	Penyusunan analisis data	...	...	...
10	Penyusunan kesimpulan atau rekomendasi	...	...	...

Bandung, 3 Juli 2026

Alfandito Rais Akbar

NIM: 18222037

ABSTRAK

Algoritma Face Recognition Dengan One-Shot Query Untuk Pencarian Foto Otomatis Berdasarkan Foto Selfie

oleh

Alfandito Rais Akbar

18222037

isi

Kata kunci: Smart Scale, Internet of Things, Edge Computing, Rantai Pasok Jeruk.

KATA PENGANTAR

Puji syukur kami panjatkan ke hadirat Tuhan Yang Maha Esa karena atas rahmat dan karunia-Nya, saya dapat menyelesaikan penulisan Laporan Tugas Akhir yang berjudul "Implementasi Algoritma XYZ untuk Optimasi Jaringan Komputer". Laporan ini disusun sebagai salah satu syarat untuk menyelesaikan program Sarjana di Sekolah Teknik Elektro dan Informatika, Institut Teknologi Bandung.

Bandung, 20 Mei 2026

Penulis

Alfandito Rais Akbar

DAFTAR ISI

LEMBAR PENGESAHAN	iii
PERNYATAAN ORISINALITAS	v
PERNYATAAN PENGGUNAAN AI	vii
ABSTRAK	ix
KATA PENGANTAR	xi
DAFTAR ISI	xiii
DAFTAR GAMBAR	xvii
DAFTAR TABEL	xix
DAFTAR PERSAMAAN	xxi
DAFTAR ALGORITMA	xxiii
DAFTAR <i>LISTING</i>	xxv
DAFTAR SIMBOL	xxvii
DAFTAR SINGKATAN	xxxix
I PENDAHULUAN	1
I.1 Latar Belakang	1
I.2 Rumusan Masalah	2
I.3 Tujuan	3
I.4 Metodologi	3
I.5 Sistematika Penulisan	4
II STUDI LITERATUR	5
II.1 Pengenalan Wajah <i>Face Recognition</i>	5
II.2 Alur dan Komponen Sistem <i>Face Recognition</i>	5
II.3 Deteksi Wajah (<i>Face Detection</i>)	5
II.3.1 MTCNN (<i>Multi-task Cascaded Convolutional Networks</i>)	6
II.3.2 SCRFD (<i>Sample and Computation Redistribution for Face Detection</i>)	7
II.3.3 Perbandingan Prinsip Kerja dan <i>Trade-off</i>	8
II.4 Pra-pemrosesan dan Normalisasi (<i>Preprocessing and Alignment</i>)	8
II.4.1 <i>Affine Transformation</i>	9
II.4.2 <i>Similarity Transformation</i>	9
II.4.3 Perbandingan Prinsip Kerja dan <i>Trade-off</i>	10
II.5 Ekstraksi Fitur Wajah (<i>Feature Extraction / Face Representation</i>)	10
II.5.1 Metode Berbasis Geometri (<i>Geometry-based Methods</i>)	11
II.5.2 Metode Holistik (<i>Holistic Methods</i>)	12
II.5.3 Metode Berbasis Fitur (<i>Feature-based Methods</i>)	13
II.5.4 Metode Hibrida (<i>Hybrid Methods</i>)	14
II.5.5 Metode <i>Deep Learning</i> (<i>Deep Learning Methods</i>)	15
II.6 Pencocokan Wajah (<i>Face Matching</i>)	16
II.6.1 <i>Cosine Similarity</i>	16
II.6.2 <i>Euclidean Similarity (Euclidean Distance)</i>	17
II.6.3 Perbandingan Prinsip Kerja dan <i>Trade-off</i>	18
II.7 <i>One-Shot Learning</i>	18

II.8	<i>Content-Based Image Retrieval (CBIR)</i>	19
II.9	<i>Semantic-Based Image Retrieval</i>	19
II.10	Penelitian yang Relevan	20
II.10.1	Metode Konvensional dan Relevansinya pada Sumber Daya Terbatas	20
II.10.2	Metode <i>Deep Learning</i> dan Tantangan Efisiensi	21
III	ANALISIS MASALAH	23
III.1	Analisis Kondisi Saat Ini	23
III.1.1	Analisis Proses Bisnis Pencarian Foto Pribadi	23
III.2	Analisis Kebutuhan	24
III.2.1	Kebutuhan Fungsional	24
III.2.2	Kebutuhan Nonfungsional	26
III.2.3	<i>Use Case Diagram</i>	26
III.3	Analisis Pemilihan Solusi	27
III.3.1	Peluang Teknologi	27
III.3.2	Analisis Penentuan Solusi	28
III.4	Analisis Permasalahan Algoritma <i>Face Recognition</i>	29
III.4.1	Ketahanan Algoritma (<i>Algorithm Robustness</i>)	30
III.4.2	Efisiensi Sumber Daya (<i>Resource Efficiency</i>)	30
IV	PERANCANGAN	33
IV.1	Diagram Konseptual Sistem	33
IV.1.1	Sistem Sebelum (<i>As-Is</i>)	33
IV.1.2	Sistem Sesudah (<i>To-Be</i>)	34
IV.1.3	Perbandingan Sistem <i>As-Is</i> dan <i>To-Be</i>	34
IV.2	Penjelasan Desain Solusi Sistem	34
IV.3	Algoritma <i>Face Recognition</i>	36
IV.3.1	Eksplorasi Algoritma Solusi	36
IV.3.2	Parameter Perbandingan	37
IV.4	Arsitektur Sistem	38
IV.4.1	Penjelasan Vektor Fitur	39
IV.4.2	Penyimpanan Tanpa Database (<i>Zero-DB Storage Architecture</i>)	40
IV.4.3	Data Flow	40
IV.5	Rencana Pengujian Sistem	42
IV.5.1	Metode Pengujian	42
IV.5.2	Parameter Keberhasilan	43
IV.6	Gambaran Penggunaan Riil Sistem Usulan	43
V	IMPLEMENTASI	45
V.1	Lingkungan Implementasi	45
V.2	Analisis Perbandingan Algoritma	46
V.2.1	Perbandingan F1-Score	46
V.2.2	Evaluasi Waktu Komputasi	47
V.2.3	Evaluasi Penggunaan Memori	48
V.2.4	Hasil Perbandingan Lengkap	48
V.3	Algoritma yang Dipilih	49

V.4	Implementasi Sistem Produksi	51
V.4.1	Arsitektur Komponen Perangkat Lunak	52
V.4.2	Pemrosesan Latar Belakang dan <i>Thread Safety</i>	53
V.4.3	Pengindeksan Inkremental dan Pemrosesan <i>Chunk</i>	53
VI	EVALUASI	55
VI.1	Metode Evaluasi	55
VI.1.1	Pengujian Fungsional	55
VI.1.2	Pengujian Akurasi	55
VI.1.3	Pengujian Performa	56
VI.1.4	Pengujian Stabilitas	56
VI.2	Hasil Evaluasi	56
VI.2.1	Hasil Pengujian Fungsional	56
VI.2.2	Hasil Pengujian Akurasi	57
VI.2.3	Hasil Pengujian Performa	57
VI.2.4	Hasil Pengujian Stabilitas	58
VI.3	Pembahasan Hasil Evaluasi	58
VI.3.1	Pemenuhan Parameter Keberhasilan	58
VI.3.2	Analisis Pengaruh Optimasi ONNX Runtime	59
VI.3.3	Keterbatasan Sistem yang Teridentifikasi	59
VII	PENUTUP	61
VII.1	Kesimpulan	61
VII.2	Saran	61
Lampiran A	KODE PROGRAM	67
A.1	Perangkat Lunak untuk Akuisisi Data dari Sensor Ultrasonik	67
A.2	Perangkat Lunak untuk Pengolahan Data Akuisisi dan Visualisasi Hasil Pengukuran Jarak	68
Lampiran B	HASIL SURVEI LAPANGAN	69
B.1	Foto Survei Lokasi 1	69
B.2	Foto Survei Lokasi 2	69
B.3	Transkrip Wawancara dengan Narasumber	69

DAFTAR GAMBAR

II.1	Alur <i>Face Recognition</i> secara umum	6
III.1	Alur Pencarian Foto dari Ruang Penyimpanan	24
III.2	<i>Use Case Diagram</i>	26
IV.1	Alur Sistem <i>As-Is</i>	33
IV.2	Alur Sistem <i>To-Be</i>	34
IV.3	Alur <i>Preprocessing</i> Sistem	35
IV.4	Alur Sistem (<i>query</i>)	36
IV.5	Arsitektur Sistem	39
IV.6	Diagram <i>Data Flow</i> Sistem	41
V.1	Perbandingan F1-Score Seluruh Model dengan Detektor MTCNN .	47
V.2	Perbandingan F1-Score Seluruh Model dengan Detektor SCRFD . .	48
V.3	Perbandingan Waktu Komputasi Seluruh Model dengan Detektor MTCNN	49
V.4	Perbandingan Waktu Komputasi Seluruh Model dengan Detektor SCRFD	50
V.5	Perbandingan Penggunaan Memori Seluruh Model dengan Detektor MTCNN	51
V.6	Perbandingan Penggunaan Memori Seluruh Model dengan Detektor SCRFD	52

DAFTAR TABEL

III.1 <i>Functional Requirement</i>	25
III.2 <i>Non-Functional Requirement</i>	25
III.3 Perbandingan Peluang Teknologi	29
IV.1 Perbandingan Sistem Awal dan Usulan	35
IV.2 Indikator Keberhasilan	43
V.1 Hasil Perbandingan Lengkap (8 Model) dengan Detektor MTCNN dan SCRFD	54
VI.1 Pengaruh Nilai <i>Threshold</i> terhadap Perilaku Sistem	57
VI.2 Hasil Pengukuran Waktu Komputasi <i>Pipeline</i> (1.000 Foto)	58

DAFTAR PERSAMAAN

DAFTAR ALGORITMA

DAFTAR *LISTING*

VI.1	Contoh Format Berkas <i>Ground Truth</i> JSON	55
A.1	Binary search code	67

DAFTAR SIMBOL

Notasi	Deskripsi	Pemakaian pertama kali
α	Koefisien bobot untuk <i>loss function</i> , tingkat signifikansi statistik	75
β	Koefisien bobot untuk <i>Binary Cross-Entropy loss</i>	75
λ	Koefisien bobot untuk CTC <i>loss</i> , parameter regularisasi	75
θ	Parameter model <i>neural network</i>	75
σ	Deviasi standar	75
μ	Rata-rata (<i>mean</i>)	75
ϵ	<i>Token blank</i> /kosong dalam CTC, konstanta kecil untuk stabilitas numerik	75
Δ	Delta (selisih/perubahan nilai)	75
π	<i>Alignment path</i> dalam CTC	75
π_t	<i>Token</i> pada <i>timestep</i> t dalam <i>alignment path</i>	76
∇ atau ∂	Operator gradien atau turunan parsial	75
$\sum$	Operator penjumlahan	75
$\prod$	Operator perkalian	75
$\int$	Operator integral	75
argmax	Argumen yang memaksimalkan fungsi	76
$\sim$	Terdistribusi menurut	75
$\rightarrow$	Menuju atau konvergen ke	75
$\mathcal{L}$	Fungsi <i>loss</i> (kerugian)	75
$\mathcal{L}_{total}$	Total <i>loss function</i>	75
$\mathcal{L}_{adversarial}$ atau $\mathcal{L}_{adv}$	<i>Adversarial loss</i>	75
$\mathcal{L}_{reconstruction}$	<i>Reconstruction loss</i>	75
$\mathcal{L}_{L1}$	L1 <i>loss</i> (<i>Mean Absolute Error</i>)	75
$\mathcal{L}_{L2}$	L2 <i>loss</i> (<i>Mean Squared Error</i>)	75
$\mathcal{L}_{CTC}$	CTC (<i>Connectionist Temporal Classification</i>) <i>loss</i>	75
$\mathcal{L}_{perceptual}$	<i>Perceptual loss</i>	75

$\mathcal{L}_{pixel}$	<i>Pixel-wise loss</i>	75
$\mathcal{L}_{BCE}$	<i>Binary Cross-Entropy loss</i>	75
$\mathcal{L}_{GAN}$	<i>GAN loss</i>	75
$\mathcal{L}_{cycle}$	<i>Cycle consistency loss</i>	75
G	<i>Generator dalam GAN</i>	75
D	<i>Discriminator dalam GAN</i>	75
$G(z)$	<i>Output dari generator dengan input z</i>	75
$D(x)$	<i>Output dari discriminator dengan input x</i>	75
$G_{A \rightarrow B}$	<i>Generator dari domain A ke B</i>	75
$G_{B \rightarrow A}$	<i>Generator dari domain B ke A</i>	75
$V(D, G)$	<i>Fungsi nilai (value function) dalam GAN</i>	75
x	<i>Sampel data asli, input citra</i>	75
y	<i>Label atau ground truth, kondisi dalam conditional GAN</i>	75
z	<i>Noise vector atau representasi laten</i>	
$\mathbb{E}$	<i>Ekspektasi atau nilai harapan</i>	75
p_{data}	<i>Distribusi data asli</i>	75
p_z	<i>Distribusi prior (noise)</i>	75
$p(y x)$	<i>Probabilitas bersyarat output y given input x</i>	75
$p_t(\pi_t x)$	<i>Probabilitas token pada timestep t</i>	
$\mathcal{B}$	<i>Fungsi penciutan (collapse function) dalam CTC</i>	75
$\mathcal{B}^{-1}$	<i>Fungsi invers penciutan dalam CTC</i>	75
T	<i>Jumlah timestep atau panjang sequence</i>	
$ x - G(y) _1$	<i>L1 distance antara ground truth dan generated image</i>	75
$ x - G(y) _2$	<i>L2 distance antara ground truth dan generated image</i>	75
$N \times N$	<i>Ukuran patch dalam PatchGAN</i>	
d	<i>Cohen's d (effect size)</i>	75
n	<i>Jumlah sampel</i>	75
p	<i>p-value (nilai probabilitas statistik)</i>	75

r	Koefisien korelasi	75
R^2	Koefisien determinasi	
$O(n)$	Notasi Big-O untuk kompleksitas linear	75
$O(n^2)$	Notasi Big-O untuk kompleksitas kuadratik	75

DAFTAR SINGKATAN

Singkatan	Deskripsi	Pemakaian pertama kali
AI	<i>Artificial Intelligence</i>	1
CNN	<i>Convolutional Neural Network</i>	2
GPU	<i>Graphics Processing Unit</i>	14

BAB I

PENDAHULUAN

I.1 Latar Belakang

Perkembangan teknologi digital dan penggunaan media penyimpanan berbasis *cloud* telah menyebabkan peningkatan jumlah data visual, khususnya foto digital. Pasar fotografi digital global diproyeksikan tumbuh dari \$53.14 miliar pada tahun 2024 menjadi \$70.95 miliar pada tahun 2029, didorong oleh lonjakan pengguna gawai (The Business Research Company 2025). Pertumbuhan pasar ini mengindikasikan bahwa jumlah foto digital yang ada juga semakin meningkat. Akibatnya, pengguna memiliki banyak foto yang tersimpan di perangkat pribadi atau layanan *cloud* seperti Google Drive, OneDrive, dan sebagainya. Hal ini sejalan dengan pertumbuhan pasar penyimpanan *cloud* global yang memperkirakan akan berkembang dari \$161.28 miliar pada tahun 2025 menjadi \$639.40 miliar pada tahun 2032 (Fortune Business Insights 2025). Perkembangan jumlah foto digital ini menciptakan permasalahan baru mengenai Manajemen Informasi Pribadi (*Personal Information Management*), yang tantangannya bukan lagi soal keterbatasan ruang, tetapi tentang kesulitan dalam penemuan kembali informasi (*information retrieval*).

Dalam konteks foto pribadi (foto yang mengandung wajah pengguna), proses pencarian foto secara manual memakan waktu yang lama karena pengguna harus membuka dan memeriksa setiap foto satu per satu. Praktik ini jelas tidak efisien, sehingga menimbulkan kebutuhan akan sebuah sistem yang dapat secara otomatis mengenali dan mengelompokkan foto berdasarkan identitas wajah pengguna.

Dengan kemajuan teknologi *Computer Vision* dan *Machine Learning*, khususnya pada bidang Pengenalan Wajah (*Face Recognition*), memungkinkan untuk dapat mengembangkan sistem yang mampu mendeteksi dan mengidentifikasi wajah seseorang secara otomatis. Pengenalan wajah itu sendiri didefinisikan sebagai metode biometrik untuk mengidentifikasi atau memverifikasi seseorang dengan membandingkan pola fitur wajah mereka. Dalam implementasinya, pengguna cukup mengambil sebuah foto *selfie*, dan sistem akan secara otomatis melakukan pencarian terhadap

seluruh foto yang mengandung wajah pengguna di dalam folder atau drive tertentu. Pendekatan ini merupakan aplikasi praktis dari paradigma *one-shot query*, yang berarti sistem mampu membuat prediksi yang benar meskipun hanya diberikan satu contoh dari kelas baru, dalam hal ini berarti wajah pengguna (Albayati 2024).

Dalam Tugas Akhir ini, akan dilakukan eksplorasi terhadap berbagai algoritma pengenalan wajah. Meskipun algoritma modern menunjukkan akurasi yang sangat tinggi di lingkungan terkontrol, kinerjanya dapat menurun saat dihadapkan pada skenario aslinya. Eksplorasi ini bertujuan untuk menemukan metode yang paling efektif dan akurat dalam mendeteksi serta mengenali wajah pada kondisi foto yang bervariasi, misalnya perbedaan pencahayaan, pose, ekspresi wajah, dan resolusi gambar.

Diharapkan sistem ini dapat memberikan solusi yang efisien dalam proses pencarian foto pribadi, sekaligus memberikan kontribusi pada pengembangan sistem pengenalan wajah yang adaptif dan mudah diterapkan untuk kebutuhan personal maupun organisasi.

1.2 Rumusan Masalah

Berdasarkan latar belakang masalah yang telah disusun, maka rumusan masalah yang menjadi fokus pembahasan dalam penyusunan Tugas Akhir ini adalah: "Bagaimana merancang dan mengimplementasikan sistem pencarian otomatis foto pribadi berbasis pengenalan wajah dengan memanfaatkan satu foto selfie sebagai acuan pencarian (*query*), dan algoritma pengenalan wajah apa yang paling efektif dan akurat dalam mendeteksi serta mengenali wajah pengguna pada kondisi foto yang bervariasi, sehingga mampu memberikan hasil pencarian terbaik dalam konteks foto pribadi?"

Proses pencarian foto pribadi secara konvensional masih sangat manual. Proses iterasi yang dilakukan ketika memeriksa foto satu per satu sangat menghabiskan waktu dan tidak efisien. Permasalahan ini menciptakan peluang untuk mengembangkan sistem yang dapat mempercepat pencarian foto pribadi dari ruang penyimpanan pribadi atau *cloud*.

Urgensi penyelesaian masalah ini cukup tinggi. Akan tetapi, sistem ini sangat dibutuhkan untuk mempercepat proses pencarian. Dengan adanya sistem ini, proses konvensional lama dapat terotomatisasi dengan lebih cepat. Selain itu, hasil dari pencarian menjadi konsisten dan tidak terpengaruhi oleh pengguna.

Solusi yang diusulkan adalah mengembangkan sistem pencarian foto pribadi menggunakan *face recognition* dengan *one-shot query*. Harapannya sistem dapat digunak-

an untuk mengotomatisasi proses pencarian dan menghasilkan hasil yang akurat.

I.3 Tujuan

Berdasarkan rumusan masalah yang telah disusun, maka tujuan dari penyusunan Tugas Akhir ini adalah sebagai berikut:

1. Merancang dan melakukan implementasi sistem pencarian otomatis foto pribadi dari folder yang disimpan di perangkat pribadi maupun layanan *cloud*, berbasis *face recognition*, dengan melakukan proses identifikasi dan penyortiran foto secara efisien menggunakan satu foto *selfie* sebagai data acuan (*query*).
2. Mengeksplorasi dan menentukan algoritma *face recognition* yang paling efektif dan akurat untuk digunakan dalam mendeteksi serta mengenali wajah pengguna pada berbagai kondisi foto, seperti perbedaan pencahayaan, pose, ekspresi, dan resolusi gambar, guna memperoleh hasil pencarian terbaik.

I.4 Metodologi

Tugas Akhir ini menggunakan pendekatan kuantitatif dengan metode eksperimental dan rekayasa sistem. Pendekatan kuantitatif dipilih karena Tugas Akhir berfokus pada pengukuran performa sistem secara objektif dan numerik, meliputi tingkat akurasi pengenalan wajah, waktu pemrosesan, serta akurasi algoritma terhadap variasi kondisi foto.

Metode eksperimental digunakan untuk menguji beberapa algoritma pengenalan wajah dengan tujuan menentukan algoritma yang paling efektif dalam konteks pencarian foto pribadi berbasis *face recognition*.

Rekayasa sistem dilakukan dengan menggunakan metodologi *Software Development Life Cycle* (SDLC) model *waterfall*. Metode ini dipilih karena memberikan struktur pengembangan yang sistematis, mulai dari analisis kebutuhan hingga evaluasi hasil implementasi. Secara umum, tahapan rekayasa sistem meliputi:

1. Analisis Kebutuhan
Pada tahap ini dilakukan identifikasi terhadap permasalahan utama pengguna. Selanjutnya, dilakukan penyusunan kebutuhan fungsional dan nonfungsional dari sistem yang akan dibangun.
2. Desain Sistem
Tahap ini mencakup perancangan arsitektur dan alur kerja sistem. Selain itu, menentukan teknologi yang digunakan dalam implementasi sistem.
3. Implementasi
Tahap ini mencakup pengembangan sistem secara penuh menggunakan tek-

nologi dan arsitektur yang telah ditentukan sebelumnya.

4. Pengujian dan Evaluasi

Tahap ini bertujuan untuk mengukur dan membandingkan performa sistem berdasarkan metrik yang telah ditentukan. Evaluasi dilakukan agar sistem dapat memberikan hasil terbaik dalam melakukan operasi.

5. Dokumentasi dan Analisis Hasil

Tahap ini mencakup dokumentasi hasil Tugas Akhir, pembahasan hasil evaluasi, serta analisis kesesuaian antara tujuan Tugas Akhir dan hasil yang diperoleh. Dari hasil analisis, diharapkan kesimpulan yang ditarik dapat menjawab permasalahan utama Tugas Akhir ini.

I.5 Sistematika Penulisan

Tugas akhir ini disusun secara runut, ringkas, dan mudah dipahami agar pembaca dapat mengikuti alur kegiatan kerja praktik secara menyeluruh. Adapun struktur laporan yang digunakan adalah sebagai berikut:

1. Bab I Pendahuluan: Berisi latar belakang, rumusan masalah, tujuan, batasan masalah, metodologi, dan sistematika penulisan laporan tugas akhir.
2. Bab II Studi Literatur: Berisi kajian pustaka yang relevan dengan topik tugas akhir, termasuk teori-teori, konsep-konsep, dan hasil-hasil penelitian sebelumnya yang mendukung pelaksanaan tugas akhir.
3. Bab III Analisis: Berisi penjelasan tentang analisis masalah dan kebutuhan pengguna serta berbagai alternatif solusinya.
4. Bab IV Perancangan: Berisi penjelasan tentang perancangan solusi yang diusulkan, misalnya arsitektur sistem, desain basis data, antarmuka pengguna, dan sebagainya.
5. Bab V Implementasi: Berisi penjelasan tentang proses implementasi solusi yang diusulkan, termasuk langkah-langkah yang diambil, teknologi yang digunakan, dan hasil yang diperoleh.
6. Bab VI Evaluasi: Berisi analisis dan evaluasi terhadap solusi yang diimplementasikan, termasuk metode pengujian, hal-hal yang disiapkan sebelum pengujian, hasil pengujian, dan penilaian kinerja.
7. Bab VII Kesimpulan dan Saran: Berisi kesimpulan dari hasil pelaksanaan tugas akhir dan saran untuk pengembangan lebih lanjut.
8. Daftar Pustaka: Berisi daftar referensi yang digunakan dalam penyusunan laporan tugas akhir.
9. Lampiran: Berisi dokumen-dokumen pendukung seperti kode program, data lengkap hasil pengujian, rekaman wawancara, dan lain-lain.

BAB II

STUDI LITERATUR

II.1 Pengenalan Wajah *Face Recognition*

Pengenalan wajah (*Face Recognition*) adalah teknologi yang mampu mengidentifikasi atau memverifikasi identitas subjek dalam gambar atau video. Teknologi ini telah menjadi salah satu bidang penelitian yang paling banyak dikaji dalam ranah *computer vision* dan biometrika. *face recognition* dianggap sebagai salah satu aplikasi biometrik yang paling umum digunakan, sering kali lebih disukai daripada metode lain seperti sidik jari atau pengenalan iris karena sifatnya yang tidak mengganggu (Trigueros, Meng, dan Hartnett 2018).

Teknologi ini memiliki beragam aplikasi, mulai dari sistem keamanan rumah, pengawasan, kontrol perbatasan, hingga kontrol akses, deteksi penipuan, verifikasi identitas, dan media sosial.


Meskipun populer, *face recognition* tetap menjadi salah satu tantangan biometrik yang paling kompleks, terutama ketika diterapkan di lingkungan yang tidak terkontrol (*in-the-wild*). Hal ini disebabkan oleh tingginya variabilitas yang dapat muncul pada gambar wajah, seperti perbedaan pose kepala, penuaan, oklusi (misalnya masker atau kacamata), kondisi pencahayaan, serta ekspresi wajah.

II.2 Alur dan Komponen Sistem *Face Recognition*

Sistem pengenalan wajah biasanya terdiri dari beberapa *building blocks* atau komponen utama. Menurut Albayati (2024), secara umum, alur *face recognition* melibatkan tiga teknik kunci, yaitu deteksi wajah, ekstraksi fitur, dan pengenalan wajah (Gambar II.1). Secara lebih rinci, alur *face recognition* mencakup empat tahapan inti, yaitu deteksi wajah, penyelarasan wajah, representasi wajah (ekstraksi fitur), dan pencocokan wajah (Trigueros, Meng, dan Hartnett 2018).

II.3 Deteksi Wajah (*Face Detection*)

Tahapan ini bertujuan untuk mendeteksi keberadaan wajah pada citra digital. Sistem akan menemukan posisi wajah dan mengembalikan koordinat kotak pembatas



Gambar II.1 Alur *Face Recognition* secara umum

(*bounding box*) untuk setiap wajah yang terdeteksi. Keberhasilan tahap ini sangat penting karena menjadi masukan bagi tahap selanjutnya, dan kinerjanya dapat dipengaruhi oleh variasi pencahayaan serta pose wajah (Albayati 2024).

Algoritma deteksi wajah berbasis *deep learning* umumnya dikelompokkan menjadi dua pendekatan besar berdasarkan mekanisme penentuan kandidat wajah, yaitu pendekatan *anchor-based* dan pendekatan *anchor-free*. Pendekatan *anchor-based* menempatkan sejumlah kotak referensi (*anchor boxes*) berukuran dan rasio tertentu pada setiap lokasi citra, kemudian jaringan memprediksi pergeseran (*offset*) serta skor klasifikasi terhadap setiap *anchor* tersebut. Sebaliknya, pendekatan *anchor-free* memprediksi langsung titik pusat atau batas objek dari setiap lokasi pada peta fitur tanpa bergantung pada kotak referensi yang telah ditentukan sebelumnya, sehingga mengurangi jumlah *hyperparameter* terkait desain *anchor* serta menurunkan kompleksitas komputasi pada tahap pasca-pemrosesan seperti *Non-Maximum Suppression* (NMS). MTCNN merupakan representasi pendekatan *anchor-based*, sedangkan SCRFD merupakan representasi pendekatan *anchor-free*.

II.3.1 MTCNN (*Multi-task Cascaded Convolutional Networks*)

MTCNN diusulkan menurut Zhang dkk. (2016) sebagai kerangka kerja deteksi dan penyelarasan wajah secara bersamaan (*joint detection and alignment*), dengan memanfaatkan korelasi inheren antara kedua tugas tersebut untuk saling meningkatkan kinerja satu sama lain. Prinsip kerja utama MTCNN terletak pada arsitektur kaskade (*cascaded architecture*) tiga tahap yang memproses citra secara bertingkat dari kasar (*coarse*) menuju halus (*fine*):

1. *Proposal Network (P-Net)*

Jaringan konvolusional dangkal yang dengan cepat menghasilkan kandidat wajah awal beserta perkiraan kotak pembatasnya dari citra yang telah diubah dalam berbagai skala (*image pyramid*), untuk mengantisipasi wajah berukuran berbeda-beda.

2. *Refine Network (R-Net)*

Jaringan penyaring kandidat hasil P-Net dengan menolak sebagian besar kandidat yang bukan wajah (*false positive*) serta memperhalus posisi kotak pembatas yang tersisa.

3. **Output Network (O-Net)**

Tahap akhir yang menghasilkan keputusan akhir keberadaan wajah, regresi kotak pembatas yang lebih presisi, sekaligus memprediksi lokasi lima titik *landmark* wajah (kedua mata, hidung, dan dua sudut mulut) dalam satu proses keluaran.

Ketiga jaringan tersebut dilatih secara *multi-task* untuk memprediksi tiga hal sekaligus dalam satu kali proses, yaitu klasifikasi wajah/bukan-wajah, regresi kotak pembatas, dan lokalisasi *landmark*, sehingga deteksi dan penyelarasan kasar wajah dapat diperoleh dalam satu alur pemrosesan yang saling melengkapi. MTCNN turut memperkenalkan strategi *online hard sample mining* yang secara otomatis memfokuskan pelatihan pada sampel-sampel sulit, tanpa memerlukan pemilihan sampel secara manual, sehingga akurasi model dapat meningkat tanpa intervensi tambahan (Zhang dkk. 2016).

II.3.2 SCRFD (*Sample and Computation Redistribution for Face Detection*)

SCRFD diusulkan menurut Guo dkk. (2021) sebagai pendekatan deteksi wajah *anchor-free* yang dirancang untuk mencapai kompromi terbaik antara akurasi dan efisiensi komputasi. Berbeda dengan MTCNN yang memproses citra secara bertahap melalui tiga jaringan terpisah, SCRFD bekerja dalam satu jaringan tunggal (*single-stage detector*) yang dioptimalkan melalui dua strategi utama:

1. **Sample Redistribution (SR)**

Berfungsi untuk menambah proporsi sampel pelatihan pada tahap-tahap jaringan yang paling membutuhkan, berdasarkan statistik distribusi skala wajah pada kumpulan data acuan, sehingga jaringan lebih mampu mendeteksi wajah berukuran kecil pada citra beresolusi rendah.

2. **Computation Redistribution (CR)**

Berfungsi untuk mengalokasikan ulang beban komputasi antara bagian *backbone*, *neck*, dan *head* dari jaringan, melalui metodologi pencarian arsitektur (*architecture search*) yang dirancang secara sistematis, alih-alih menggunakan distribusi komputasi yang seragam seperti pada arsitektur konvensional.

Pada tahap pemadanan kandidat wajah, SCRFD memanfaatkan *Adaptive Training Sample Selection* (ATSS) untuk menentukan sampel positif secara adaptif berdasarkan statistik sebaran objek, alih-alih menggunakan ambang batas *Intersection over Union* (IoU) yang tetap seperti pada pendekatan *anchor-based* klasik. Fungsi

loss yang digunakan adalah *Generalised Focal Loss* (GFL) untuk cabang klasifikasi dan *Distance-IoU Loss* (DIOU) untuk cabang regresi kotak pembatas. Kombinasi strategi ini menjadikan SCRFD mampu mencapai kompromi akurasi-efisiensi yang unggul (*state-of-the-art efficiency-accuracy trade-off*) dibandingkan metode *anchor-based* sejenis, terutama pada rentang anggaran komputasi yang rendah, sehingga relevan digunakan pada aplikasi dengan kendala sumber daya seperti perangkat *edge* atau aplikasi *desktop offline* (Guo dkk. 2021).

II.3.3 Perbandingan Prinsip Kerja dan *Trade-off*

Secara prinsip, perbedaan mendasar antara MTCNN dan SCRFD terletak pada penentuan kandidat wajah dan jumlah tahap pemrosesan. MTCNN, sebagai metode *anchor-based* bertahap, cenderung memiliki latensi yang lebih tinggi karena citra harus melewati tiga jaringan terpisah secara berurutan, namun keunggulannya terletak pada kesederhanaan implementasi dan kematangan dukungan pustaka. Sebaliknya, SCRFD sebagai metode *anchor-free* satu tahap memproses deteksi dan estimasi landmark secara lebih efisien dalam satu kali proses, sehingga unggul dari sisi kecepatan inferensi, terutama pada pemrosesan citra dalam jumlah besar. Selain itu, presisi lokasi yang dihasilkan SCRFD relatif lebih konsisten karena tidak dibatasi oleh diskretisasi ukuran dan rasio *anchor* yang telah ditentukan sebelumnya, sehingga kualitas potongan wajah (*crop*) yang dihasilkan cenderung lebih baik sebagai masukan bagi komponen representasi wajah pada tahap selanjutnya.

II.4 Pra-pemrosesan dan Normalisasi (*Preprocessing and Alignment*)

Setelah wajah terdeteksi, tahap penyelarasan (*alignment*) atau pemrosesan wajah dilakukan. Tujuannya adalah untuk menyesuaikan skala, rotasi, dan memotong gambar wajah secara konsisten guna mengatasi masalah yang disebabkan oleh variasi pose, pencahayaan, dan oklusi (Trigueros, Meng, dan Hartnett 2018).

Penyelarasan ini penting karena variasi pose dan sudut pengambilan gambar dapat memperbesar perbedaan dalam-kelas (*intra-class variance*) apabila tidak dinormalisasi terlebih dahulu, sehingga menurunkan akurasi komponen representasi wajah pada tahap berikutnya (Wang dan Deng 2021).

Pendekatan 2D yang umum digunakan untuk penyelarasan wajah memanfaatkan sepasang himpunan titik *landmark*: titik yang terdeteksi pada citra wajah (*source points*) dan titik referensi tetap (*reference/target points*) yang merepresentasikan tata letak wajah ideal. Transformasi geometris kemudian dihitung untuk memetakan titik sumber sedekat mungkin ke titik referensi tersebut. Dua jenis transformasi yang umum digunakan untuk keperluan ini adalah transformasi *affine* (*affine transforma-*

tion) dan transformasi kesamaan (*similarity transformation*).

II.4.1 Affine Transformation

Transformasi *affine* adalah transformasi geometris yang mempertahankan sifat garis lurus dan paralelisme antar garis, namun tidak selalu mempertahankan sudut maupun panjang. Transformasi ini memiliki enam derajat kebebasan (*6 Degrees of Freedom*, 6-DoF), yang mencakup translasi, rotasi, penskalaan (*scaling*), perubahan rasio aspek (*aspect ratio*), dan pencondongan (*shear*). Secara umum, transformasi affine dapat dinyatakan dalam bentuk perkalian matriks dan penjumlahan vektor translasi sebagaimana pada Persamaan II.1.

$$\begin{bmatrix} x' & y' \end{bmatrix} = \begin{bmatrix} a & b; & c & d \end{bmatrix} \cdot \begin{bmatrix} x & y \end{bmatrix} + \begin{bmatrix} t_x & t_y \end{bmatrix} \quad (\text{II.1})$$

dengan $\begin{bmatrix} x & y \end{bmatrix}$ adalah koordinat titik pada citra asal, dan $\begin{bmatrix} x' & y' \end{bmatrix}$ adalah koordinat titik hasil transformasi, matriks $\begin{bmatrix} a & b; & c & d \end{bmatrix}$ mengatur rotasi, penskalaan, dan pencondongan, serta $\begin{bmatrix} t_x & t_y \end{bmatrix}$ adalah vektor translasi. Untuk memperoleh matriks transformasi ini, diperlukan minimal tiga pasang titik korespondensi yang membentuk sebuah sistem persamaan linear, yang kemudian diselesaikan agar titik-titik sumber berpindah sedekat mungkin dengan titik-titik referensi. Karena memiliki enam derajat kebebasan, transformasi *affine* mampu menangani distorsi bentuk yang lebih kompleks dibandingkan transformasi kesamaan, namun risikonya adalah kemampuannya mengubah rasio aspek wajah secara berlebihan apabila titik landmark yang terdeteksi kurang presisi, sehingga berpotensi mendistorsi proporsi wajah asli (Wang dan Deng 2021; Zhao dkk. 2003).

II.4.2 Similarity Transformation

Transformasi kesamaan (*similarity transformation*) merupakan kasus khusus dari transformasi affine yang membatasi derajat kebebasan menjadi empat (*4 Degrees of Freedom*, 4-DoF), yaitu translasi, rotasi, dan penskalaan seragam (*uniform scaling*), tanpa melibatkan pencondongan atau perubahan rasio aspek. Karena penskalaannya bersifat seragam pada seluruh sumbu, transformasi ini termasuk dalam kelompok transformasi tegar (*rigid transformation*) yang diperluas dengan faktor skala, sehingga bentuk relatif antar titik *landmark* (proporsi wajah) tetap terjaga setelah transformasi diterapkan (Wang dan Deng 2021).

Berbeda dari transformasi *affine* yang memerlukan minimal tiga titik korespondensi, transformasi kesamaan secara teoretis dapat diestimasi dari minimal dua titik

landmark, meskipun penggunaan lima titik (kedua mata, hidung, dan dua sudut mulut) lebih umum dipakai pada metode *face recognition* modern karena memberikan estimasi yang lebih stabil. Pendekatan ini banyak digunakan pada metode representasi wajah berbasis *deep learning* seperti *ArcFace* dan *FaceNet*, karena rasio aspek wajah yang konsisten lebih krusial dipertahankan dibandingkan kemampuan menangani distorsi bentuk yang kompleks, sehingga membantu menjaga karakteristik geometris wajah tetap proporsional sebelum masuk ke tahap ekstraksi fitur.

II.4.3 Perbandingan Prinsip Kerja dan *Trade-off*

Trade-off utama antara kedua jenis transformasi terletak pada jumlah derajat kebebasan yang digunakan. Transformasi *affine*, dengan enam derajat kebebasan, lebih fleksibel dalam menyesuaikan distorsi bentuk wajah yang kompleks akibat variasi pose atau sudut pengambilan gambar, namun fleksibilitas tersebut juga membawa risiko terjadinya distorsi rasio aspek wajah yang tidak diinginkan, terutama apabila estimasi titik *landmark* kurang akurat. Sebaliknya, transformasi kesamaan, dengan hanya empat derajat kebebasan, lebih terbatas dalam menangani distorsi bentuk, namun keterbatasan ini justru menjadi keunggulan karena proporsi asli wajah tetap terjaga, sehingga representasi fitur yang dihasilkan pada tahap berikutnya menjadi lebih konsisten dan dapat diprediksi. Karena alasan inilah, sebagian besar metode *deep learning* untuk representasi wajah modern cenderung memilih transformasi kesamaan sebagai metode penyelarasan standar, sedangkan transformasi *affine* lebih banyak digunakan pada konteks yang memang menuntut koreksi bentuk yang lebih agresif, seperti normalisasi pose non-frontal menuju pose frontal (Wang dan Deng 2021).

II.5 Ekstraksi Fitur Wajah (*Feature Extraction* / *Face Representation*)

Pada tahap representasi wajah, nilai piksel dari citra wajah diubah menjadi sebuah vektor fitur yang ringkas dan diskriminatif, yang juga dikenal sebagai *template*. Secara ideal, seluruh citra wajah dari subjek yang sama seharusnya dipetakan ke vektor fitur yang memiliki kemiripan satu sama lain (Trigueros, Meng, dan Hartnett 2018).

Face representation merupakan komponen inti dalam sistem pengenalan wajah, dan efektivitasnya sangat bergantung pada kemampuan sistem dalam menghasilkan representasi wajah yang kuat dan diskriminatif. Menurut Trigueros, Meng, dan Hartnett (2018), secara tegas menyatakan bahwa representasi wajah bisa dibilang merupakan komponen terpenting dari sistem pengenalan wajah. Hal ini menegaskan bahwa kualitas representasi menentukan keberhasilan setiap tahap dalam proses identifikasi maupun verifikasi.

Pada tahap ini, citra wajah yang telah melalui proses deteksi dan penyalarsan diubah menjadi sebuah *feature vector* yang ringkas dan mampu membedakan identitas satu individu dengan individu lainnya. Vektor ini berfungsi sebagai *template* yang menjadi dasar proses pencocokan wajah. Tujuan utama dari representasi tersebut adalah memastikan bahwa seluruh citra wajah dari subjek yang sama, terlepas dari variasi sudut pandang, pencahayaan, atau ekspresi, dapat dipetakan ke *feature vector* yang serupa. Tanpa representasi yang akurat dan konsisten, sistem tidak akan mampu melakukan identifikasi dengan baik.

Perkembangan teknologi pengenalan wajah pada dasarnya merupakan perjalanan panjang dalam mencari cara menghasilkan representasi wajah yang semakin baik. Pada metode tradisional, *features* dirancang secara manual menggunakan pendekatan seperti *Local Binary Patterns (LBP)* atau *Gabor*, dengan tujuan membuat representasi tahan terhadap perubahan kondisi. Namun, kemunculan metode *deep learning*, terutama *Convolutional Neural Networks (CNN)*, menjadi terobosan besar karena jaringan ini mampu mempelajari representasi secara otomatis dari jumlah data yang sangat besar, tanpa perlu perancangan *features* manual oleh peneliti.

Walaupun tahap deteksi dan penyalarsan memainkan peran penting dalam mempersiapkan citra masukan, kualitas akhir sistem tetap sangat bergantung pada kemampuan tahap representasi dalam menghasilkan *features* yang benar-benar dapat membedakan identitas individu. Bahkan tahap pencocokan wajah, yang hanya menghitung tingkat kemiripan antara dua *vectors*, sepenuhnya bergantung pada kualitas representasi tersebut. Jika representasi gagal membedakan dua individu yang berbeda, maka algoritma pencocokan yang paling canggih sekalipun tidak akan mampu menghasilkan identifikasi yang benar. Dengan demikian, *Face Recognition* merupakan tahap yang sangat kritis dan menjadi fondasi utama bagi keberhasilan keseluruhan sistem pengenalan wajah (Trigueros, Meng, dan Hartnett 2018).

Metode representasi wajah dapat dikelompokkan ke dalam lima kategori besar berdasarkan strategi ekstraksi fiturnya, yaitu metode berbasis geometri, metode holistik, metode berbasis fitur lokal, metode hibrida, dan metode *deep learning*.

II.5.1 Metode Berbasis Geometri (*Geometry-based Methods*)

Metode berbasis geometri merupakan salah satu pendekatan paling awal dalam riset *face recognition*, yang merepresentasikan wajah melalui sekumpulan parameter geometris yang diukur dari lokasi titik-titik fitur penting (*fiducial points*) seperti mata, hidung, mulut, dan kontur dagu. Prinsip kerja metode ini diawali dengan deteksi lokasi titik-titik fitur tersebut, kemudian dihitung serangkaian parameter kuantita-

tif berupa jarak antar fitur (misalnya, jarak interokular), ukuran komponen wajah (misalnya, lebar dan panjang hidung), serta sudut-sudut relasional antar fitur, yang kemudian dikompilasi menjadi sebuah vektor fitur berdimensi rendah (Brunelli dan Poggio 1993; Zhao dkk. 2003).

Brunelli dan Poggio (1993) membandingkan pendekatan berbasis fitur geometris ini dengan pendekatan *template matching* pada kumpulan data wajah yang sama, dan menemukan bahwa meskipun pendekatan geometris menghasilkan tingkat pengenalan yang cukup baik (sekitar 90%), pendekatan *template matching* menunjukkan performa yang lebih unggul pada kumpulan data pengujian yang digunakan. Keunggulan utama metode berbasis geometri terletak pada kecepatan komputasi yang tinggi dan kebutuhan memori yang rendah, karena vektor fiturnya hanya berisi sejumlah kecil nilai numerik dibandingkan representasi citra penuh. Namun demikian, akurasi pengenalannya sangat bergantung pada presisi deteksi titik fitur, sehingga rentan terhadap kesalahan apabila kondisi citra mengalami variasi pencahayaan, pose, atau ekspresi wajah yang signifikan, dan secara umum akurasinya lebih rendah dibandingkan metode yang memanfaatkan informasi tekstur atau gradien citra secara langsung (Trigueros, Meng, dan Hartnett 2018).

II.5.2 Metode Holistik (*Holistic Methods*)

Berbeda dengan metode berbasis geometri yang hanya menggunakan sebagian kecil titik fitur, metode holistik merepresentasikan wajah menggunakan keseluruhan area piksel wajah sebagai masukan. Prinsip kerja metode ini umumnya memproyeksikan citra wajah berdimensi tinggi ke dalam ruang berdimensi rendah yang lebih ringkas, dengan tujuan membuang informasi atau detail yang tidak relevan untuk proses pengenalan.

Principal Component Analysis (PCA), atau yang dikenal sebagai *eigenfaces*, merupakan pendekatan holistik yang paling banyak digunakan. PCA bekerja dengan mencari arah proyeksi linear yang memaksimalkan total sebaran (*total scatter*) dari seluruh data wajah, sehingga secara teknis optimal untuk merekonstruksi kembali citra (*reconstruction*) dari representasi berdimensi rendah tersebut. Setiap wajah direpresentasikan sebagai kombinasi linear dari sejumlah basis citra (*eigenfaces*), dan proses pengenalan dilakukan dengan mencocokkan bobot proyeksi dari citra baru terhadap bobot-bobot yang telah tersimpan dalam basis data (Belhumeur, Hespanha, dan Kriegman 1997; Zhao dkk. 2003).

Keunggulan utama PCA terletak pada kesederhanaan implementasi serta efisiensi dalam merepresentasikan variasi data secara keseluruhan menggunakan jumlah

komponen yang relatif sedikit. Namun, karena PCA bersifat *unsupervised* dan mengoptimalkan rekonstruksi citra secara umum (bukan secara spesifik memaksimalkan keterpisahan antar identitas), metode ini cenderung sensitif terhadap variasi pencahayaan, ekspresi, dan pose, karena variasi-variasi tersebut dapat mendominasi komponen utama (*principal components*) yang dihasilkan, alih-alih variasi yang berkaitan dengan perbedaan identitas wajah (Belhumeur, Hespanha, dan Kriegman 1997).

II.5.3 Metode Berbasis Fitur (*Feature-based Methods*)

Berbeda dengan metode holistik yang memproses citra wajah secara keseluruhan, metode berbasis fitur memanfaatkan fitur lokal yang diekstraksi dari berbagai lokasi spesifik pada citra wajah, sehingga cenderung lebih tangguh (*robust*) terhadap variasi lokal seperti ekspresi wajah atau pencahayaan yang tidak merata (Trigueros, Meng, dan Hartnett 2018).

Local Binary Patterns (LBP) bekerja dengan membandingkan nilai intensitas setiap piksel terhadap piksel-piksel tetangganya dalam suatu wilayah lokal (misalnya, wilayah 3×3 piksel), menghasilkan suatu kode biner yang merepresentasikan pola tekstur lokal di sekitar piksel tersebut. Distribusi kode-kode biner ini kemudian dikumpulkan dalam bentuk histogram untuk setiap wilayah (*region*) pada citra wajah, dan seluruh histogram wilayah digabungkan menjadi satu vektor fitur tunggal yang merepresentasikan tekstur wajah secara keseluruhan. Karena hanya membandingkan intensitas relatif antar piksel tetangga (bukan nilai intensitas absolut), LBP relatif tangguh terhadap perubahan pencahayaan monoton (misalnya, perubahan kecerahan global), namun representasi histogramnya cenderung berdimensi tinggi dan kurang optimal dalam menangkap struktur tepi (*edge*) berskala besar pada wajah (Ahonen, Hadid, dan Pietikainen 2006; Trigueros, Meng, dan Hartnett 2018).

Histogram of Oriented Gradients (HOG), diusulkan oleh Dalal dan Triggs (2005), bekerja dengan menghitung gradien intensitas citra pada setiap piksel, kemudian mengelompokkan orientasi gradien tersebut ke dalam histogram untuk setiap sel (*cell*) kecil pada citra. Histogram-histogram dari sel-sel yang berdekatan kemudian dikelompokkan dan dinormalisasi dalam blok (*block*) yang saling tumpang tindih (*overlapping*), bertujuan menjaga invariansi terhadap perubahan pencahayaan dan bayangan lokal. Prinsip dasar HOG adalah bahwa bentuk dan tampilan suatu objek lokal sering kali dapat dideskripsikan dengan baik melalui distribusi arah tepi atau gradien intensitasnya, sehingga HOG unggul dalam menangkap struktur kontur wajah seperti garis rahang, alis, dan bentuk hidung. HOG awalnya dirancang untuk deteksi pejalan kaki, namun terbukti efektif diadaptasi untuk representasi wajah ka-

rena kemampuannya menangkap struktur bentuk secara lebih eksplisit dibandingkan LBP yang berfokus pada tekstur (Albiol dkk. 2008; Dalal dan Triggs 2005).

Trade-off antara LBP dan HOG terletak pada jenis informasi visual yang ditangkap: LBP lebih unggul dalam merepresentasikan tekstur permukaan kulit dan pola lokal yang halus, sedangkan HOG lebih unggul dalam merepresentasikan bentuk dan kontur wajah secara struktural. Kedua metode ini relatif ringan secara komputasi dibandingkan metode *deep learning*, namun keduanya tetap merupakan fitur hasil rancangan manual (*hand-crafted features*) yang tidak dipelajari secara otomatis dari data, sehingga kemampuan generalisasinya terhadap variasi kondisi citra yang ekstrem (pose ekstrem, oklusi berat) relatif terbatas dibandingkan representasi yang dipelajari (*learned representation*) oleh jaringan saraf tiruan.

II.5.4 Metode Hibrida (*Hybrid Methods*)

Metode hibrida menggabungkan teknik dari metode berbasis fitur dan metode holistik, dengan tujuan memperoleh keunggulan dari kedua pendekatan tersebut sekaligus. Prinsip kerja umumnya diawali dengan mengekstraksi fitur lokal (misalnya menggunakan LBP) dari citra wajah, kemudian fitur lokal berdimensi tinggi tersebut diproyeksikan ke dalam sub-ruang berdimensi rendah yang lebih ringkas dan diskriminatif menggunakan teknik reduksi dimensi holistik seperti PCA (Trigueros, Meng, dan Hartnett 2018).

Kombinasi LBP + PCA bekerja dengan terlebih dahulu mengekstraksi histogram LBP dari citra wajah sebagaimana dijelaskan pada bagian II.5.3, kemudian vektor histogram tersebut yang umumnya berdimensi tinggi karena terdiri atas gabungan histogram dari banyak wilayah lokal direduksi dimensinya menggunakan PCA untuk membuang redundansi informasi dan derau (*noise*), sekaligus mempercepat proses pencocokan pada tahap selanjutnya. Pendekatan ini berupaya mengatasi salah satu kelemahan utama PCA murni, yaitu sensitivitasnya terhadap variasi piksel mentah, dengan terlebih dahulu mengekstraksi representasi tekstur lokal yang lebih tangguh melalui LBP, sebelum reduksi dimensi dilakukan.

Trade-off dari pendekatan hibrida ini adalah peningkatan kompleksitas komputasi dibandingkan penggunaan LBP atau PCA secara terpisah, karena memerlukan dua tahap pemrosesan berurutan. Namun, kompleksitas tambahan ini umumnya sepadan dengan peningkatan akurasi yang diperoleh, karena kombinasi fitur lokal yang tangguh terhadap variasi tekstur dengan reduksi dimensi yang menghilangkan redundansi cenderung menghasilkan representasi yang lebih ringkas dan lebih diskriminatif dibandingkan kedua metode penyusunnya bila digunakan sendiri-sendiri (Trigueros,

Meng, dan Hartnett 2018).

II.5.5 Metode *Deep Learning* (*Deep Learning Methods*)

Metode berbasis *deep learning*, khususnya jaringan saraf konvolusional (*Convolutional Neural Network*, CNN), menjadi standar terkini dalam representasi wajah karena kemampuannya mempelajari fitur secara otomatis dan langsung dari data pelatihan berskala besar, alih-alih bergantung pada fitur hasil rancangan manual seperti pada metode geometri, holistik, maupun berbasis fitur lokal. Prinsip kerja umumnya adalah melatih jaringan untuk memetakan citra wajah ke dalam suatu ruang *embedding* berdimensi rendah, di mana jarak antar vektor *embedding* merepresentasikan tingkat kemiripan identitas. Perbedaan utama antar arsitektur *deep learning* terletak pada desain *backbone* jaringan dan fungsi *loss* yang digunakan untuk melatihnya (Trigueros, Meng, dan Hartnett 2018).

VGG-Face, diusulkan oleh Parkhi, Vedaldi, dan Zisserman (2015), memanfaatkan arsitektur *Very Deep Convolutional Networks* (VGGNet) yang dilatih pada kumpulan data wajah berskala besar untuk menghasilkan representasi yang diskriminatif. Karakteristik VGGNet adalah penggunaan tumpukan lapisan konvolusi berukuran kecil (3×3) secara berurutan dan mendalam, sehingga menghasilkan medan reseptif (*receptive field*) yang besar sembari mempertahankan jumlah parameter yang relatif terkendali. *Trade-off* utama arsitektur ini adalah jumlah parameter dan kebutuhan memori yang relatif besar dibandingkan arsitektur lain yang lebih efisien, karena kedalaman jaringan dan lebar lapisan (*feature map*) yang besar membutuhkan alokasi memori untuk aktivasi antara (*intermediate activation*) yang signifikan.

FaceNet, diusulkan oleh Schroff, Kalenichenko, dan Philbin (2015), memperkenalkan pendekatan *unified embedding* yang memetakan citra wajah secara langsung ke ruang *Euclidean* berdimensi rendah, dengan jarak antar *embedding* merepresentasikan tingkat kemiripan wajah secara langsung tanpa memerlukan lapisan klasifikasi tambahan. FaceNet dilatih menggunakan *Triplet Loss*, yang mengoptimalkan jaringan agar jarak antara sampel *anchor* dengan sampel identitas yang sama (*positive*) lebih kecil dibandingkan jarak dengan sampel identitas berbeda (*negative*) dengan margin tertentu. *Trade-off* utama pendekatan *Triplet Loss* adalah proses pelatihan yang relatif kompleks, karena memerlukan strategi pemilihan triplet yang tepat (*triplet mining*) agar pelatihan dapat konvergen secara efektif, mengingat jumlah kombinasi triplet yang mungkin tumbuh secara kubik terhadap ukuran data pelatihan (Schroff, Kalenichenko, dan Philbin 2015).

ArcFace (*Additive Angular Margin Loss*), diusulkan oleh Deng dkk. (2019), memo-

difikasi fungsi *Softmax* konvensional dengan menambahkan margin sudut (*angular margin*) secara aditif pada sudut antara fitur dan bobot kelas yang bersesuaian di ruang hiperbola (*hypersphere*). Berbeda dengan *Triplet Loss* yang membandingkan jarak antar tiga sampel sekaligus, ArcFace bekerja layaknya fungsi klasifikasi pada umumnya namun dengan penalti margin geometris yang eksplisit, sehingga proses pelatihannya relatif lebih stabil dan tidak memerlukan strategi *mining triplet* yang rumit. Penambahan margin secara aditif pada sudut, alih-alih pada nilai kosinus seperti pendekatan sejenis (misalnya, CosFace), memberikan ArcFace interpretasi geometris yang konsisten dengan jarak busur (*geodesic distance*) pada permukaan hiperbola, sehingga representasi fitur yang dihasilkan menjadi lebih kompak pada kelas yang sama (*intra-class compactness*) sekaligus lebih terpisah antar kelas yang berbeda (*inter-class discrepancy*) dibandingkan fungsi loss berbasis Softmax konvensional maupun *Triplet Loss* (Deng dkk. 2019).

Trade-off umum dari ketiga arsitektur *deep learning* tersebut terletak pada keseimbangan antara kapasitas representasi (yang umumnya berkorelasi dengan ukuran model dan kebutuhan memori) dan efisiensi komputasi. VGG-Face cenderung menghasilkan representasi dengan kapasitas tinggi namun pada beban memori yang besar; FaceNet menghasilkan *embedding* yang ringkas namun proses pelatihannya menuntut strategi *triplet mining* yang lebih rumit; sedangkan ArcFace menawarkan kestabilan pelatihan serta kemampuan diskriminatif yang tinggi melalui penalti margin sudut yang eksplisit, dengan kebutuhan memori *inference* yang relatif ringan karena ukuran *embedding* yang ringkas (umumnya 512 dimensi), menjadikannya pilihan yang umum pada aplikasi dengan kendala sumber daya.

II.6 Pencocokan Wajah (*Face Matching*)

Tahap *face matching* (pencocokan wajah) adalah tahap akhir dalam alur *face recognition*. Dua vektor *embedding* wajah dibandingkan untuk menghasilkan suatu skor kemiripan (*similarity score*) yang menunjukkan seberapa besar kemungkinan kedua *embedding* tersebut berasal dari individu yang sama (Trigueros, Meng, dan Hartnett 2018). Dua metrik jarak/kemiripan yang paling umum digunakan untuk membandingkan vektor *embedding* wajah adalah kesamaan kosinus (*cosine similarity*) dan jarak Euclidean (*Euclidean distance*).

II.6.1 *Cosine Similarity*

Kesamaan kosinus mengukur kosinus sudut antara dua vektor pada ruang berdimensi- n , tanpa memperhitungkan magnitudo (panjang) dari masing-masing vektor. Diberikan dua vektor *embedding* A dan B, kesamaan kosinus dirumuskan pada Persama-

an II.2.

$$\cos(A, B) = \frac{A \cdot B}{\|A\| \times \|B\|} \quad (\text{II.2})$$

dengan $A \cdot B$ adalah hasil perkalian titik (*dot product*) antara kedua vektor, serta $\|A\|$ dan $\|B\|$ masing-masing adalah norma *Euclidean* (panjang) dari vektor A dan B . Nilai kesamaan kosinus berada pada rentang $[-1, 1]$, dengan nilai 1 menunjukkan kedua vektor memiliki arah yang identik, nilai 0 menunjukkan tidak ada korelasi arah, dan nilai -1 menunjukkan arah yang berlawanan. Karena hanya memperhitungkan arah vektor (bukan magnitudonya), kesamaan kosinus secara alami invarian terhadap penskalaan (*scale-invariant*), sehingga sangat sesuai digunakan pada representasi yang dihasilkan oleh model berbasis margin pada ruang hiperbola seperti ArcFace, di mana proses pelatihan model tersebut memang secara eksplisit mengoptimalkan sudut antar *embedding*, bukan jaraknya secara absolut (Deng dkk. 2019).

II.6.2 *Euclidean Similarity (Euclidean Distance)*

Jarak *Euclidean* mengukur jarak garis lurus (*straight-line distance*) antara dua titik pada ruang berdimensi- n , dan merupakan metrik jarak yang paling intuitif secara geometris. Diberikan dua vektor *embedding* A dan B , jarak *Euclidean* dirumuskan pada Persamaan II.3.

$$d(A, B) = \|A - B\| = \sqrt{\sum_{i=1}^n (A_i - B_i)^2} \quad (\text{II.3})$$

dengan A_i dan B_i adalah nilai komponen ke- i dari masing-masing vektor A dan B . Berbeda dengan kesamaan kosinus, jarak *Euclidean* memperhitungkan baik arah maupun magnitudo vektor, sehingga nilai jarak ini dapat dipengaruhi oleh perbedaan skala atau normalisasi panjang vektor *embedding*. Semakin kecil nilai jarak *Euclidean*, semakin besar kemiripan antara dua wajah. Sebaliknya, nilai yang besar mengindikasikan identitas yang berbeda. Metrik ini umum digunakan pada model yang dilatih dengan fungsi loss berbasis jarak secara langsung, seperti *Triplet Loss* pada FaceNet, karena proses pelatihannya memang secara eksplisit mengoptimalkan jarak *Euclidean* antar *embedding* (Schroff, Kalenichenko, dan Philbin 2015).

II.6.3 Perbandingan Prinsip Kerja dan *Trade-off*

Trade-off mendasar antara kedua metrik ini terletak pada sensitivitas terhadap magnitudo vektor. Kesamaan kosinus mengabaikan magnitudo dan hanya berfokus pada arah, sehingga lebih tangguh terhadap perbedaan skala *embedding* yang mungkin timbul akibat variasi kontras atau intensitas wajah, namun informasi mengenai seberapa kuat suatu fitur terdeteksi (yang tercermin dari magnitudo) menjadi hilang. Sebaliknya, jarak *Euclidean* memperhitungkan magnitudo secara penuh, sehingga lebih sensitif terhadap variasi skala, namun dapat menangkap informasi tambahan apabila representasi *embedding* memang tidak dinormalisasi terlebih dahulu.

Dalam praktiknya, kedua metrik ini saling berkaitan erat: apabila vektor *embedding* dinormalisasi terlebih dahulu hingga memiliki panjang satuan (*unit length*, $\|A\| = \|B\| = 1$), maka jarak *Euclidean* kuadrat antara dua vektor tersebut menjadi fungsi linear langsung dari kesamaan kosinusnya, yaitu pada Persamaan II.4.

$$\|A - B\|^2 = 2 - 2 \cdot \cos(A, B) \quad (\text{II.4})$$

Dengan demikian, pemilihan salah satu metrik pada kondisi *embedding* yang telah dinormalisasi pada dasarnya menghasilkan urutan pemeringkatan kemiripan (*similarity ranking*) yang setara, dan perbedaannya hanya terletak pada skala serta interpretasi nilai ambang batas (*threshold*) yang digunakan untuk menentukan kecocokan identitas (Deng dkk. 2019).

II.7 *One-Shot Learning*

One-Shot Learning (OSL) adalah paradigma inferensi di mana sebuah sistem mampu membuat prediksi yang benar meskipun hanya diberikan satu contoh dari kelas yang dituju, tanpa perlu melatih ulang model untuk kelas tersebut (Albayati 2024). Kemampuan ini meniru cara manusia mengenali wajah yang belum pernah dijumpai sebelumnya: cukup dengan satu kali melihat, manusia dapat mengenali wajah yang sama pada pertemuan berikutnya.

Berbeda dengan pendekatan *deep learning* konvensional yang memerlukan ratusan hingga ribuan sampel per individu untuk melatih sebuah *classifier* baru, sistem berbasis OSL memanfaatkan model yang telah dilatih sebelumnya (*pre-trained model*) pada kumpulan data wajah berskala besar untuk menghasilkan representasi fitur (*embedding*) yang bersifat generik dan diskriminatif. Pada saat inferensi, model tidak dilatih ulang, melainkan *embedding* dari satu sampel referensi langsung dibandingk-

an terhadap *embedding* dari sampel-sampel target menggunakan metrik kemiripan (Albayati 2024).

Dalam konteks Tugas Akhir ini, paradigma OSL diterapkan dalam bentuk *one-shot query*: pengguna cukup memberikan satu foto *selfie* sebagai acuan pencarian. *Embedding* wajah dari foto *selfie* tersebut diekstraksi oleh model *pre-trained* dan kemudian dibandingkan terhadap *embedding* seluruh wajah yang terdeteksi pada foto-foto dalam folder target. Foto-foto yang menghasilkan skor kemiripan di atas nilai ambang batas (*threshold*) yang telah ditentukan akan dikembalikan sebagai hasil pencarian, tanpa memerlukan proses pelatihan atau pendaftaran identitas tambahan oleh pengguna.

II.8 Content-Based Image Retrieval (CBIR)

Content-Based Image Retrieval (CBIR) didefinisikan sebagai sistem krusial dalam bidang *computer vision* yang memungkinkan pencarian dan temu kembali gambar berdasarkan analisis konten visualnya secara langsung, alih-alih bergantung pada metadata tekstual seperti kata kunci atau *tag*. Dalam konteks ini, konten visual diterjemahkan sebagai fitur tingkat rendah (*low-level features*) yang diekstraksi dari citra, yang meliputi karakteristik warna, tekstur, dan bentuk. Secara operasional, mekanisme kerja CBIR dimulai dengan tahap ekstraksi fitur di mana atribut visual diambil untuk membangun representasi konten dari gambar tersebut. Algoritma sistem kemudian membandingkan representasi fitur dari gambar *query* (*input* pengguna) dengan representasi fitur dari seluruh gambar yang tersimpan dalam basis data. Proses ini bertujuan untuk mengambil gambar-gambar yang memiliki tingkat kemiripan visual tertinggi dengan kueri. Meskipun efektif dalam mengidentifikasi kesamaan visual, kinerja CBIR sering kali dihadapkan pada tantangan *semantic gap*, yaitu kesenjangan antara fitur visual tingkat rendah dan konsep semantik tingkat tinggi yang dipahami manusia, sehingga integrasi metode seperti *Relevance Feedback* (RF) sering diperlukan untuk menjembatani kesenjangan tersebut dan meningkatkan akurasi pencarian (Qazanfari, AlyanNezhadi, dan Khoshdaregi 2023).

II.9 Semantic-Based Image Retrieval

Semantic Image Retrieval didefinisikan sebagai pendekatan strategis untuk menjembatani kesenjangan semantik (*semantic gap*) antara fitur visual tingkat rendah (seperti tekstur dan warna) dengan konsep semantik tingkat tinggi yang dipahami manusia, yang bertujuan menciptakan proses temu kembali yang tidak hanya akurat tetapi juga dapat dijelaskan (*interpretable*). Metode utama yang diterapkan untuk mencapai hal ini adalah *Bag-of-Words Association Mapping*, yang diawali dengan

tahapan ekstraksi fitur mendalam melalui teknik pemotongan citra dua kali (*double slicing*) guna menangkap detail objek kecil, diikuti dengan pengambilan fitur tekstur menggunakan *Local Binary Pattern* (LBP) dan fitur warna berbasis momen.

Fitur-fitur visual yang telah diekstraksi kemudian dipecah menjadi kata-kata visual (*visual words*) menggunakan algoritma *K-means clustering* untuk membentuk kamus fitur. Untuk menerjemahkan kata-kata visual ini menjadi makna, sistem menerapkan algoritma *Improved FP-Growth* yang berfungsi menambang aturan asosiasi yang kuat antara pola visual dan label semantik, lengkap dengan perhitungan nilai kepercayaan (*confidence*) untuk setiap aturan. Pada tahap akhir, proses pencarian dilakukan dengan menghitung kemiripan menggunakan metode TF-IDF yang dikombinasikan dengan probabilitas aturan, serta diperkuat oleh mekanisme umpan balik (*feedback mechanism*) yang secara dinamis mengoreksi bobot probabilitas semantik pada hasil yang salah untuk meningkatkan presisi pencarian di masa depan (Li dkk. 2023).

II.10 Penelitian yang Relevan

Bagian ini akan menjelaskan mengenai penelitian sebelumnya yang relevan dengan Tugas Akhir ini. Penelitian tersebut akan digunakan sebagai fondasi sebagai *research gap* untuk meningkatkan keterbaruan Tugas Akhir ini.

II.10.1 Metode Konvensional dan Relevansinya pada Sumber Daya Terbatas

Penelitian terdahulu yang dirangkum oleh Zhao dkk. (2003) mengklasifikasikan metode pengenalan wajah ke dalam pendekatan holistik, berbasis fitur, dan hibrida. Metode holistik seperti *Principal Component Analysis* (PCA) dinilai efisien untuk rekonstruksi wajah namun memiliki kelemahan signifikan terhadap variasi pencahayaan, sedangkan *Linear Discriminant Analysis* (LDA) terbukti lebih unggul dalam membedakan identitas asalkan tersedia sampel pelatihan yang cukup. Di sisi lain, metode berbasis fitur seperti *Elastic Bunch Graph Matching* (EBGM) dianggap lebih tangguh terhadap perubahan pose, meskipun kinerjanya sangat bergantung pada akurasi deteksi fitur lokal yang sering kali tidak stabil.

Meskipun metode-metode ini sering dianggap usang dalam literatur modern, penelitian ini menyoroti bahwa metode seperti LDA memiliki keunggulan teoritis dalam kondisi komputasi ringan dan sampel terbatas. Namun, literatur yang ada kurang mengeksplorasi secara empiris apakah efisiensi dan kesederhanaan metode konvensional ini masih menjadikannya solusi terbaik (paling optimal) dibandingkan metode modern untuk skenario dengan sumber daya perangkat keras yang sangat terbatas atau ketika data pelatihan sangat sedikit.

II.10.2 Metode *Deep Learning* dan Tantangan Efisiensi

Penelitian oleh Trigueros, Meng, dan Hartnett (2018) menyoroti pergeseran paradigma dari fitur buatan tangan (*hand-crafted*) menuju fitur yang dipelajari secara otomatis (*learned features*) melalui *deep learning*. Mereka menegaskan bahwa metode tradisional telah banyak digantikan oleh *convolutional neural networks* (CNNs) karena kemampuan CNN mempelajari fitur diskriminatif dari data berskala besar, yang membuatnya jauh lebih tangguh terhadap variasi ekstrem seperti pose dan ekspresi wajah (*faces in-the-wild*) . Arsitektur seperti *DeepFace* dan *FaceNet* telah menetapkan standar baru dalam akurasi pengenalan wajah.

Penelitian ini menunjukkan superioritas akurasi CNN. Penelitian ini juga mencatat adanya ketergantungan yang tinggi pada komputasi berat dan *dataset* masif (jutaan gambar) untuk menghindari *overfitting*. Kesenjangan yang muncul di sini adalah kurangnya studi komparatif yang mengevaluasi apakah kompleksitas dan biaya tinggi dari CNN benar-benar sepadan dengan peningkatan akurasinya untuk aplikasi skala kecil. Studi ini diperlukan untuk mengisi celah tersebut dengan membandingkan secara langsung metode *deep learning* melawan metode tradisional pada secara adil (*dataset* yang sama dan terbatas) untuk menentukan metode mana yang paling efektif secara keseluruhan, bukan hanya yang paling akurat.

BAB III

ANALISIS MASALAH

III.1 Analisis Kondisi Saat Ini


Bagian ini akan menjelaskan hasil analisis dari kondisi saat ini terkait dengan pencarian foto pribadi. Foto pribadi yang dimaksud pada Tugas Akhir merupakan foto yang mengandung wajah dari pemilik foto tersebut.

III.1.1 Analisis Proses Bisnis Pencarian Foto Pribadi

Pada kondisi saat ini, pengguna digital sering kali memiliki kumpulan foto yang disimpan dalam ruang penyimpanan lokal ataupun *cloud*. Dengan meningkatnya jumlah foto yang disimpan dalam ruang penyimpanan tersebut, semakin sulit bagi pengguna untuk mengelolanya, apalagi jika ruang penyimpanan menyimpan selain foto pengguna. Ketika pengguna ingin mencari foto pribadi (Foto yang mengandung wajah diri pengguna) dari ruang penyimpanan tersebut, pengguna akan kesulitan untuk menyaring antara foto pribadi dengan foto lainnya. Oleh karena itu, diperlukan analisis mendalam untuk mengetahui perilaku pengguna dalam menyaring foto tersebut.

Dari gambar III.1, proses pencarian/penyaringan foto pribadi masih dilakukan secara manual. Pengguna harus melakukan iterasi dengan membuka *file* foto dan melakukan cek apakah foto tersebut foto pribadi atau bukan (Yang mengandung wajah diri pengguna). Proses iterasi ini berlangsung lama, karena iterasi akan terus dilakukan hingga foto pada ruang penyimpanan sudah dicek semua. Hal ini akan menimbulkan masalah apabila jumlah foto dalam ruang penyimpanan sangat banyak, akibatnya pengguna akan mengalami kerugian waktu dengan melakukan proses penyaringan tersebut. Foto yang sudah dicek dan merupakan foto pribadi selanjutnya akan dipisahkan dari ruang penyimpanan. Pengguna dapat membuat folder atau album baru yang kemudian diisi dengan foto pribadinya.

Proses pencarian/penyaringan foto secara manual ini memiliki kekurangan. Dengan meningkatnya jumlah foto dalam ruang penyimpanan, maka akan semakin lama juga



Gambar III.1 Alur Pencarian Foto dari Ruang Penyimpanan

proses pencariannya. Pengguna perlu meluangkan waktu hanya untuk membuka dan melakukan cek terhadap foto yang disimpan. Selain itu, proses ini rawan terjadi kesalahan dalam penyaringan fotonya. Jumlah foto yang banyak dapat membuat pengguna kebingungan dan lupa dengan foto yang sudah di cek dan foto pribadi dari ruang penyimpanan. Akibatnya, pengguna bisa mengulangi proses cek terhadap foto yang sudah di cek sebelumnya. Kedua masalah tersebut akan rawan terjadi seiring dengan meningkatnya jumlah foto yang disimpan dalam ruang penyimpanan.

III.2 Analisis Kebutuhan

Berdasarkan hasil analisis kondisi saat ini dari sistem, maka akan dilakukan penyusunan kebutuhan (*Requirement*) untuk membantu dalam perancangan solusi. Kebutuhan akan dibagi menjadi dua, yaitu kebutuhan fungsional (*Functional Requirement*) dan kebutuhan nonfungsional (*Non-Functional Requirement*).

III.2.1 Kebutuhan Fungsional

Berdasarkan hasil analisis kondisi, diperlukan suatu sistem yang dapat menyelesaikan permasalahan utama yang didapat. Sistem yang dirancang harus dapat memudahkan dan memangkas waktu tunggu pengguna dalam mencari/menyaring foto pribadi yang disimpan baik dalam ruang penyimpanan lokal ataupun *cloud*.

Tabel III.1 *Functional Requirement*

Kode	Nama Kebutuhan
FR1	Sistem dapat menerima masukan berupa kumpulan foto dari pengguna dalam satu masukan.
FR2	Sistem dapat mengidentifikasi foto pribadi (Yang mengandung wajah diri pengguna) dari kumpulan foto pengguna yang telah di- <i>input</i> .
FR3	Sistem dapat memisahkan dan menyimpan foto pribadi yang telah diidentifikasi dalam satu <i>list</i> sebagai keluaran dari sistem.

Tabel III.2 *Non-Functional Requirement*

Kode	Aspek	Nama Kebutuhan
NF1	<i>Performance</i>	Sistem dapat memproses rata-rata satu foto dalam waktu kurang dari 1 detik menggunakan spesifikasi perangkat keras standar
NF2	<i>Performance</i>	Sistem memiliki tingkat akurasi (<i>accuracy</i>) minimal 85% dalam mengidentifikasi foto pribadi
NF3	<i>Reliability</i>	Sistem tidak mengalami <i>crash</i> (berhenti mendadak) saat menemui <i>file</i> gambar yang rusak (<i>corrupt</i>), format tidak didukung, atau foto tanpa wajah
NF4	<i>Scalability</i>	Sistem harus mampu memproses masukan <i>dataset</i> dalam jumlah besar (minimal 500 - 1.000 foto) dalam satu kali eksekusi tanpa mengalami kegagalan memori


Kebutuhan fungsional mencakup fungsi-fungsi utama yang harus dimiliki oleh sistem dalam memenuhi tujuan penggunaannya. Kebutuhan fungsional sistem yang dirancang harus dapat menerima kumpulan foto pengguna dalam satu masukan untuk nantinya dilakukan penyaringan didalamnya. Selanjutnya, sistem harus dapat mengidentifikasi foto pribadi dari kumpulan foto yang didapat dari masukan pengguna sebelumnya. Terakhir, sistem harus dapat memisahkan foto pribadi yang telah diidentifikasi dan memasukkannya dalam satu daftar sebagai keluaran dari sistem, sehingga pengguna dapat mengunduh hasil pencarian/penyaringan. Semua kebutuhan fungsional tersebut telah dirangkum dan diberi kode identifikasi dalam Tabel III.1 untuk memudahkan dalam dokumentasi.

III.2.2 Kebutuhan Nonfungsional

Selain fungsi-fungsi utama sistem yang telah didefinisikan sebelumnya, diperlukan kebutuhan nonfungsional sebagai fungsi pendukung untuk menentukan bagaimana sistem harus beroperasi. Kebutuhan ini berupa kebutuhan nonfungsional yang mencakup karakteristik kualitas dan batasan sistem. Kebutuhan nonfungsional mencakup aspek *Performance* (kinerja), *reliability* (keandalan), dan *scalability* (skalabilitas). Semua kebutuhan nonfungsional telah dirangkum dan diberi kode identifikasi dalam Tabel III.2 untuk memudahkan dalam dokumentasi.

III.2.3 Use Case Diagram

Berdasarkan kebutuhan fungsional yang telah didefinisikan, diperlukan analisis untuk mengetahui bagaimana fungsionalitas sistem dari perspektif pengguna. Untuk menggambarannya, digunakan *use case diagram* yang menjelaskan apa yang dapat dilakukan pengguna terhadap sistem. Diagram ini menunjukkan hubungan antara aktor (pengguna) dengan *use case* (fungsi utama) yang dapat dilakukan oleh sistem.



Gambar III.2 Use Case Diagram

Pada Gambar III.2, diagram tersebut menggambarkan interaksi antara pengguna dengan sistem pencarian foto pribadi. Pengguna disini berperan sebagai aktor utama

yang memulai alur dengan mengunggah kumpulan foto yang ingin diproses. Sistem kemudian akan melakukan identifikasi foto pribadi dari daftar foto yang sudah dimasukkan sebelumnya. Apabila foto merupakan daftar pribadi, sistem akan memisahkannya dan menyimpan foto hasil identifikasi tersebut. Ketika hasil identifikasi selesai, pengguna dapat melihat hasil pencarian dari kumpulan foto yang telah dimasukkan sebelumnya. Diagram ini menunjukkan bahwa sistem akan dirancang secara otomatis dan berurutan mulai dari masukan foto pengguna hingga menampilkan hasil pencarian, ini bertujuan untuk memudahkan dan mengurangi waktu yang diperlukan pengguna dalam proses pencarian foto pribadi.

III.3 Analisis Pemilihan Solusi

Untuk memenuhi kebutuhan sistem yang telah didefinisikan, diperlukan solusi terbaik yang dapat memenuhi aspek fungsional dan nonfungsional. Perancangan solusi akan menghasilkan alternatif-alternatif solusi, sehingga perlu untuk melakukan analisis dan penilaian untuk tiap alternatif solusi yang ada. Dengan demikian, solusi yang terbaik yang dipilih dapat menjawab tujuan dari sistem yang ingin dikembangkan.

III.3.1 Peluang Teknologi

Setelah melakukan berbagai eksplorasi terhadap peluang penggunaan teknologi untuk menyelesaikan kebutuhan utama, terdapat tiga peluang penggunaan teknologi yang mungkin digunakan.

- 1. Pendekatan Berbasis Konten Citra (*Content-Based Image Retrieval / CBIR*)**

Cara kerja pendekatan ini dengan membandingkan karakteristik visual dari foto, seperti warna dominan, tekstur, bentuk, atau pola visual lainnya. Dengan membandingkan karakteristik tersebut, sistem dapat menemukan foto yang secara visual mirip dengan contoh yang diberikan. Kelebihan dari pendekatan ini adalah dapat diterapkan tanpa memerlukan anotasi manual. Kelemahan dari pendekatan ini adalah CBIR hanya dapat mengukur kesamaan visual secara umum, sehingga tidak bisa mengukur kesamaan identitas wajah pengguna. Dua foto yang menampilkan orang berbeda tetapi memiliki pencahayaan atau latar serupa bisa saja dianggap mirip oleh sistem, sehingga tidak cocok untuk kebutuhan pencarian berbasis individu.

- 2. Pendekatan Berbasis Atribut atau Objek Semantik (*Semantic-Based Image Retrieval*)**

Metode ini memanfaatkan deteksi objek atau atribut tertentu dalam foto, seperti pakaian, latar belakang, atau aktivitas yang sedang dilakukan. Sistem dapat menyaring foto berdasarkan ciri kontekstual, misalnya foto saat mema-

kai kacamata atau foto di pantai. Pendekatan ini mampu mempersempit hasil pencarian, tetapi tidak mampu memastikan identitas pengguna secara biometrik, karena fokusnya bukan pada wajah melainkan konteks visual.

3. Pendekatan Berbasis *Face Recognition* dengan *One-Shot Learning*

Pendekatan ini menggunakan teknik *computer vision* dan *machine learning* untuk mendeteksi, mengekstraksi, dan mencocokkan ciri biometrik wajah seseorang. Dengan hanya memberikan satu foto selfie sebagai acuan (*one-shot query*), sistem dapat menemukan dan mengelompokkan semua foto yang mengandung wajah pengguna dalam *dataset*. Kelebihan utama metode ini adalah kemampuan identifikasi yang spesifik terhadap individu, tingkat akurasi tinggi, serta kemudahan penerapan pada *dataset* berskala besar. Meskipun memerlukan komputasi yang lebih tinggi dibandingkan pendekatan lain, metode ini paling relevan dan efektif untuk konteks pencarian foto pribadi yang berfokus pada identitas wajah.

III.3.2 Analisis Penentuan Solusi

Berdasarkan peluang teknologi yang dijelaskan pada bagian sebelumnya, teknologi yang paling relevan untuk digunakan pada kasus ini adalah *face recognition*. Inti dari permasalahan utama adalah identifikasi. Solusi yang dipilih harus mampu mendeteksi dan mengelompokkan foto yang mengandung wajah diri pengguna. Dari ketiga peluang teknologi, hanya *face recognition* yang secara definisi merupakan metode biometrik yang dapat mengidentifikasi atau memverifikasi seseorang dengan membandingkan pola fitur wajah. Ini menjadikan *face recognition* satu-satunya solusi yang secara spesifik menargetkan identitas individu, bukan hanya kemiripan visual umum atau konteks foto.

Dua peluang teknologi lain yang sempat dipertimbangkan tidak mampu memenuhi kebutuhan yang telah didefinisikan sebelumnya. Pada CBIR, pendekatan ini hanya mengukur kesamaan berdasarkan karakteristik visual tingkat rendah seperti warna, tekstur, atau bentuk secara umum. CBIR tidak dapat mengukur kesamaan identitas wajah yang spesifik, sehingga gagal memisahkan foto pengguna dengan foto orang lain yang mungkin memiliki latar belakang atau pencahayaan yang mirip. Sedangkan, pendekatan berbasis atribut atau objek semantik, hanya berfokus pada penyaringan berdasarkan konteks atau objek dalam foto (misalnya, mencari foto di pantai, atau foto yang memakai kacamata). Meskipun dapat mempersempit hasil, metode ini tidak mampu memverifikasi identitas pengguna secara biometrik. Analisis antara peluang teknologi dapat dilihat dengan rangkum dan terstruktur di Tabel III.3

Berdasarkan hasil analisis, pendekatan berbasis *face recognition* dengan *one-shot learning* adalah solusi yang paling relevan dan efektif karena kelebihan utamanya terletak pada kemampuan untuk melakukan identifikasi spesifik individu. Meskipun memerlukan komputasi yang lebih tinggi, metode ini secara langsung menjawab tujuan sistem untuk menyaring dan mengelompokkan foto berdasarkan identitas wajah pengguna. Oleh karena itu, eksplorasi selanjutnya akan difokuskan pada penentuan algoritma *face recognition* yang paling akurat untuk mengatasi variasi kondisi foto.

Tabel III.3 Perbandingan Peluang Teknologi

Alternatif Solusi	Kelebihan	Kekurangan	Relevansi
1. Berbasis Konten Citra (CBIR)	Dapat diterapkan tanpa memerlukan anotasi manual.	Hanya mengukur kesamaan visual secara umum, tidak dapat mengukur kesamaan identitas wajah pengguna. Rentan terhadap foto yang berbeda orang tetapi memiliki latar atau pencahayaan serupa.	Rendah
2. Berbasis Atribut Semantik	Mampu mempersempit hasil pencarian berdasarkan ciri kontekstual (misalnya, di pantai, memakai kacamata).	Tidak mampu memastikan identitas pengguna secara biometrik karena fokusnya bukan pada wajah melainkan konteks visual.	Rendah
3. Berbasis <i>Face Recognition</i>	Kemampuan identifikasi yang spesifik terhadap individu. Tingkat akurasi tinggi dan kemudahan penerapan pada <i>dataset</i> berskala besar. Mendukung paradigma <i>one-shot query</i> .	Memerlukan komputasi yang lebih tinggi dibandingkan pendekatan lain. Kinerja dapat menurun saat dihadapkan pada foto dengan variasi ekstrem (pencahayaan, pose, oklusi).	Tinggi (Solusi Pilihan)

III.4 Analisis Permasalahan Algoritma *Face Recognition*

Selain permasalahan alur proses bisnis konvensional yang masih bersifat manual, diperlukan analisis mendalam mengenai karakteristik teknis dari algoritma *face recognition* itu sendiri. Pada skenario pencarian otomatis foto pribadi berbasis *one-shot learning*, tantangan utama beralih pada aspek robustitas algoritma dalam mengenali wajah dan efisiensi konsumsi sumber daya (*resource*) perangkat keras.

III.4.1 Ketahanan Algoritma (*Algorithm Robustness*)

Algoritma *face recognition* standar sering kali mengalami penurunan performa (akurasi) yang signifikan ketika dihadapkan pada data citra dunia nyata (*in-the-wild*). Dalam konteks pencarian foto pribadi, ketidakpastian kondisi spasial dan lingkungan visual menciptakan beberapa permasalahan pada algoritma, antara lain:

1. Variasi Pencahayaan

Foto-foto yang tersimpan dalam ruang penyimpanan pengguna memiliki intensitas cahaya yang tidak seragam (misalnya foto *indoor*, *outdoor*, atau *low-light*). Perubahan pencahayaan ini mengubah distribusi nilai piksel wajah secara drastis, sehingga algoritma berbasis fitur tradisional atau linear sering kali gagal memetakan wajah tersebut ke dalam vektor representasi yang konsisten dengan kueri selfie.

2. Variasi Pose dan Ekspresi

Berbeda dengan foto kueri yang berupa selfie frontal (menghadap ke depan), foto target dalam basis data sering kali diambil secara kandid (*candid*), miring (non-frontal), atau dengan ekspresi wajah yang ekstrem. Algoritma yang tidak memiliki fitur *face alignment* yang kuat akan menghasilkan jarak *Euclidean* atau kosinus yang jauh, sehingga menyebabkan tingginya angka penolakan palsu (*False Reject Rate*).

3. Oklusi

Wajah pengguna pada foto target sering kali tertutup sebagian oleh objek lain, seperti kacamata, masker, rambut, atau intervensi tangan. Hambatan visual ini membuang sebagian informasi geometri wajah, yang dapat mengecoh algoritma jika model terlalu bergantung pada fitur wajah global secara utuh.

4. Masalah Skala Spasial Resolusi Ekstrem

Citra digital dunia nyata sering kali memiliki resolusi sangat tinggi (≥ 8 MP atau resolusi 4K). Proses inferensi menggunakan detektor wajah standar pada resolusi asli ini menyebabkan lonjakan drastis pada komputasi grafis dan memicu *Out of Memory* (OOM) pada spesifikasi perangkat keras standar. Oleh karena itu, diperlukan mekanisme *Progressive Resolution Fallback Cascade* untuk mereduksi skala citra secara adaptif ke resolusi maksimal 1080p (1920×1080 piksel) sebelum proses deteksi dilakukan.

III.4.2 Efisiensi Sumber Daya (*Resource Efficiency*)

Penggunaan paradigma *one-shot learning* menuntut adanya kompromi yang besar antara akurasi model dengan kapasitas komputasi yang tersedia. Beberapa permasalahan efisiensi sumber daya yang diidentifikasi meliputi:

1. Tingginya Kompleksitas Komputasi *Deep Learning*

Algoritma modern berbasis *Convolutional Neural Network* (CNN) dalam fase ekstraksi fitur (*face representation*) membutuhkan operasi *floating-point* yang sangat masif. Jika sistem dijalankan pada spesifikasi perangkat keras standar tanpa bantuan *Graphics Processing Unit* (GPU) eksternal, waktu pemrosesan rata-rata per foto berisiko menjadi lebih lambat.

2. Tantangan Skalabilitas Memori (*Memory Footprint*)

Ketika pengguna memasukkan dataset dalam jumlah besar, proses pemuatan citra, deteksi *bounding box*, hingga konversi menjadi feature vector berdimensi tinggi secara berurutan (*batch processing*) berpotensi menyebabkan kegagalan memori (*Out of Memory*).

3. Efisiensi Struktur Basis Data Vektor

Penyimpanan *template* berupa vektor fitur memerlukan mekanisme pencarian yang optimal. Jika pencocokan dilakukan dengan melakukan iterasi linear ($O(n)$) terhadap seluruh data vektor di dalam basis data untuk setiap pencarian, waktu tunggu akan meningkat secara kuadratik seiring bertambahnya jumlah foto target.

BAB IV

PERANCANGAN


IV.1 Diagram Konseptual Sistem

Dari solusi yang telah dipilih pada bagian sebelumnya, bagian ini akan menjelaskan mengenai perbandingan alur pencarian foto pribadi sebelum dan sesudah pengembangan sistem pencarian foto pribadi berdasarkan *selfie* dari sisi pengguna.

IV.1.1 Sistem Sebelum (*As-Is*)

Alur pencarian foto yang konvensional saat ini ditunjukkan pada Gambar IV.1. Alur dimulai dengan mengakses penyimpanan yang dapat berupa folder/*drive*. Selanjutnya untuk masing-masing *file* foto, akan dicek satu-satu untuk melihat apakah foto yang sedang dibuka tersebut adalah foto pribadi atau bukan. Ketika foto yang dibuka merupakan foto pribadi, foto tersebut akan dipisahkan atau ditandai untuk disimpan pada ruang penyimpanan yang terpisah. Apabila foto bukan foto pribadi, akan dilanjutkan dengan membuka *file* foto selanjutnya hingga semua foto sudah dicek.


Berdasarkan alur pencarian tersebut, sistem saat ini memiliki dua keterbatasan. Pertama, waktu yang diperlukan untuk melakukan cek untuk setiap foto dapat menjadi terlalu lama untuk jumlah foto yang banyak. Terakhir, rawan terjadi kesalahan ketika melakukan cek karena foto yang terlalu banyak dapat membingungkan, sehingga dapat mengakibatkan *miss*.



Gambar IV.1 Alur Sistem *As-Is*

IV.1.2 Sistem Sesudah (*To-Be*)

Sistem pencarian foto pribadi yang diusulkan ditunjukkan pada Gambar IV.2. Sistem ini mengembangkan algoritma *face recognition* dengan menggunakan *one-shot learning*. Dengan adanya sistem ini, alur iterasi yang tidak perlu dilakukan oleh pengguna akan dilakukan secara otomatis oleh sistem.



Gambar IV.2 Alur Sistem *To-Be*

Alur dimulai dengan memilih jalur direktori (*folder path*) penyimpanan foto yang tersimpan secara lokal di perangkat pengguna. Kemudian, pengguna memilih satu foto *selfie* sebagai kueri pencarian. Dari masukan tersebut, sistem kemudian akan memproses pencarian foto pribadi berdasarkan wajah yang ada di dalam foto *selfie*. Terakhir, keluaran dari sistem adalah folder berisi foto-foto pribadi yang berhasil disaring dari masukan awal.

IV.1.3 Perbandingan Sistem *As-Is* dan *To-Be*


Perbandingan antara sistem konvensional (*As-Is*) dengan sistem yang diusulkan (*To-Be*) ditunjukkan pada Tabel IV.1.

IV.2 Penjelasan Desain Solusi Sistem


Berdasarkan alur sistem dari sisi pengguna di bagian sebelumnya, alur kerja dimulai dari *preprocessing* yang ditunjukkan Gambar IV.3. Folder yang telah dipilih pengguna akan dilakukan pemrosesan oleh model *face recognition*, dimulai dari *face detection*, *face alignment*, dan *face representation*. Hasilnya vektor *embedding* dari setiap wajah yang terdeteksi akan disimpan pada folder *cache* (*.face_cache/*) di dalam direktori foto masukan dalam format JSON, beserta dengan informasi *bounding box* dan *path file*-nya.

Tabel IV.1 Perbandingan Sistem Awal dan Usulan

Parameter Perbandingan	Sistem <i>As-Is</i>	Sistem <i>To-Be</i>
Pendekatan Dasar	Manual (Manusia), pengguna melakukan inspeksi visual satu per satu.	Otomatis (Algoritma), sistem melakukan pencarian menggunakan <i>Face Recognition</i>
Masukan (<i>input</i>)	Hanya berupa akses ke penyimpanan berisi kumpulan foto	Akses penyimpanan ditambah foto <i>selfie</i> sebagai referensi
Mekanisme Proses	Iterasi manual yang diulang sebanyak jumlah foto	Iterasi sistem
Teknologi	Tidak ada teknologi cerdas	Menggunakan algoritma <i>face recognition</i> dengan pendekatan <i>one-shot learning</i>
Peran Pengguna	Aktif dan repetitif	Pasif dan hanya perlu mengunggah data di awal
Manajemen Output	Pemisahan/penandaan foto dilakukan manual oleh pengguna saat itu juga	Sistem secara otomatis menyaring dan menyimpan foto yang cocok ke dalam folder khusus



Gambar IV.3 Alur *Preprocessing* Sistem



Gambar IV.4 Alur Sistem (*query*)

Setelah *preprocessing* dilakukan, selanjutnya dilakukan penyaringan berdasarkan foto *selfie* yang dimasukkan pengguna sebagai *query*. Foto *selfie* akan diproses oleh model, sehingga bisa didapatkan hasil vektor dari foto tersebut. Hasil tersebut akan dilakukan *face matching* dengan data *embedding* yang telah tersimpan di dalam *cache*. Apabila jarak kosinus (*cosine distance*) antara *embedding selfie* dan *embedding target* berada di bawah nilai ambang batas (*threshold*) yang ditentukan, foto tersebut akan diklasifikasikan sebagai foto pribadi pengguna. Semua foto yang cocok tersebut akan dikumpulkan sebagai keluaran dari *query*. Alur sistem *query* ditunjukkan pada Gambar IV.4.

IV.3 Algoritma *Face Recognition*

Berdasarkan hasil solusi, fokus eksplorasi selanjutnya berada pada penentuan algoritma *face recognition* yang paling akurat. Bagian ini akan menjelaskan bagian eksplorasi yang akan dibandingkan dari algoritma *face recognition* yang ada.

IV.3.1 Eksplorasi Algoritma Solusi

Seperti yang telah diketahui dari Bagian II.2, *face recognition* terbagi menjadi empat blok komponen, *face detection*, *preprocessing and alignment*, *face representation*, dan *face matching*. Berdasarkan bagian II.3, dapat didebatkan bahwa komponen inti dari sistem *face recognition* adalah *face representation*. Komponen tersebut menentukan keberhasilan setiap tahap dalam proses identifikasi maupun verifikasi.

Berarti, komponen tersebut memainkan peran penting yang nantinya akan terpengaruh ke tingkat akurasi dan waktu kompleksitas dari algoritma *face recognition*.

Eksplorasi yang dilakukan dalam algoritma *face recognition* akan dilakukan pada komponen *face representation*. Dalam eksplorasi, akan dilakukan perbandingan baik dari metode tradisional hingga metode yang paling modern. Tujuan eksplorasi ini adalah untuk menemukan metode yang paling efektif dan akurat dalam mendeteksi serta mengenali wajah pada kondisi foto yang bervariasi, sesuai dengan Rumusan Masalah kedua.

Berdasarkan studi literatur pada Bagian II.5, terdapat lima kategori utama metode yang akan dieksplorasi dan dibandingkan kinerjanya dalam konteks *one-shot learning* (OSL) untuk pencarian foto pribadi:

1. Metode Berbasis Geometri (*Geometry-based Methods*)
2. Metode Holistik (*Holistic Methods*)
3. Metode Berbasis Fitur (*Feature-based Methods*)
4. Metode Hibrida (*Hybrid Methods*)
5. Metode Deep Learning (*Deep Learning Methods*)

Dari berbagai metode tersebut, masing-masing metode memiliki banyak pendekatan. Oleh karena itu, dalam eksplorasi Tugas Akhir akan membandingkan pendekatan-pendekatan tersebut sehingga mendapatkan pendekatan terbaik di setiap metodenya. Kemudian, pendekatan terbaik di setiap metode akan dibandingkan kembali dengan metode lainnya, sehingga bisa mendapatkan algoritma *face recognition* yang cocok dengan sistem yang dikembangkan.

IV.3.2 Parameter Perbandingan

Pada eksplorasi algoritma solusi, diperlukan parameter perbandingan yang bertujuan untuk menentukan algoritma yang terbaik. Parameter tersebut akan menjadi dasar dipilihnya algoritma yang akan dipilih pada sistem yang akan dibangun. Harapannya parameter tersebut dapat menjadi landasan evaluasi yang objektif dan terukur, sehingga setiap hasil dari algoritma setara dan diukur dalam metrik yang standar.

Dalam perbandingan, jumlah *dataset* yang digunakan sebagai *test case* sebaiknya standar. Jumlah *dataset* yang akan digunakan sebagai perbandingan algoritma adalah sebanyak 1000 foto, dengan *test case* yang sama untuk masing-masing algoritma.

1. Waktu Komputasi

Analisis waktu komputasi akan dilakukan dengan mencakup tahap *preprocessing*, *feature extraction*, dan *matching*. Untuk mengukur kinerja pada skala yang lebih besar, pengujian akan dilakukan secara bertahap menggunakan

jumlah *dataset* yang bervariasi, yaitu 100, 300, 500, 700, hingga 1000 foto. Hasil dari pengukuran ini akan direpresentasikan dalam bentuk grafik kinerja untuk menganalisis skalabilitas dan tren waktu pemrosesan terhadap peningkatan jumlah foto secara objektif.

2. Akurasi

Selain dari pengukuran waktu, akurasi diperlukan sebagai dasar validitas fungsional sistem. Pengukuran ini mengacu pada metrik standar seperti *precision*, *F1-Score*, *accuracy*, dan sebagainya. Untuk mendukung pengukuran ini, *dataset* pengujian (*test case*) harus memiliki anotasi label yang valid sebagai kebenaran dasar (*Ground Truth*). Hal ini memastikan bahwa setiap hasil prediksi algoritma dapat dibandingkan secara presisi terhadap identitas yang sebenarnya.

3. Kompleksitas Model

Parameter kompleksitas dievaluasi untuk mengukur viabilitas implementasi (*feasibility*). Terdapat dua pengukuran yang dilakukan, yaitu *memory footprint* dan dependensi perangkat keras (CPU, GPU, dan sebagainya). Hal ini dilakukan untuk memastikan bahwa perbandingan antar algoritma adil dari sisi konsumsi sumber daya. Dengan demikian, dapat ditentukan apakah algoritma tersebut cocok diterapkan pada lingkungan dengan sumber daya terbatas.

IV.4 Arsitektur Sistem

Sistem usulan dirancang dengan pendekatan arsitektur berorientasi layanan komponen (*component-based service*) yang mengutamakan efisiensi *resource* dengan mengeliminasi ketergantungan pada database eksternal. Seluruh data transaksi komputasi diolah secara dinamis di dalam memori, sementara berkas fisik dan hasil penyaringan dikelola langsung di dalam direktori kerja ruang penyimpanan.


Berdasarkan Gambar IV.5, arsitektur sistem didekomposisi menjadi tiga lapisan utama:

1. Frontend Layer

Layer ini berfungsi sebagai gerbang interaksi bagi pengguna untuk menyerahkan masukan (berupa folder/*drive* input dan foto kueri selfie) ke dalam sistem dan menjalankan proses pencarian.

2. Intelligence Layer

Layer ini berisi model *face recognition* yang digunakan untuk melakukan *preprocessing* terhadap data dari folder/*drive* dan mengekstrak vektor fitur dari foto kueri selfie untuk dilakukan *matching* terhadap data hasil *preprocessing* sebelumnya.



Gambar IV.5 Arsitektur Sistem

3. *Data Layer*

Layer ini berfungsi sebagai pengontrol logika utama dalam mengelola data hasil *preprocessing* dan data hasil pencarian di folder/drive masukan pengguna.

IV.4.1 Penjelasan Vektor Fitur

Dalam sistem ini, pencarian wajah menggunakan pendekatan *one-shot learning* di mana karakteristik unik wajah diekstrak menjadi representasi numerik ringkas yang disebut vektor fitur (*face embedding*).

1. Karakteristik Vektor

Setiap wajah yang terdeteksi akan dikonversi oleh *AI Engine* menjadi sebuah array satu dimensi (*ID*) bertipe data float dengan dimensi tertentu, misalnya 128 atau 512 dimensi.

2. Sifat Geometris Ruang Vektor

Vektor-vektor tersebut telah dinormalisasi menggunakan *L2 Normalization*. Melalui fungsi *loss* pada model *deep learning*, wajah dari individu yang sama akan menghasilkan koordinat vektor yang saling berdekatan di dalam ruang metrik, sedangkan wajah dari individu yang berbeda akan memiliki jarak koordinat yang berjauhan.

3. Metrik Komputasi

Pencocokan antara wajah kueri (*selfie*) dan wajah target dilakukan dengan

menghitung nilai *Cosine Similarity* atau *Euclidean Distance* antar-vektor secara instan di dalam memori kerja (*RAM*) tanpa perlu melakukan *querying* ke indeks basis data eksternal.

IV.4.2 Penyimpanan Tanpa Database (*Zero-DB Storage Architecture*)

Untuk mengatasi kendala efisiensi resource dan menyederhanakan arsitektur (sesuai dengan batasan masalah), sistem ini mengadopsi mekanisme Zero-DB. Struktur penyimpanan data diatur dengan ketentuan sebagai berikut:

1. Penyimpanan Representasi Vektor dan Metadata sebagai Cache

Sistem tidak menyediakan basis data persisten seperti *MySQL*, *PostgreSQL*, maupun *vector database* khusus. Seluruh matriks vektor fitur berukuran $N \times d$ yang diekstrak dari folder input beserta metadatanya, seperti nama file asli dan koordinat *bounding box* yang disimpan sepenuhnya di dalam direktori folder/drive masukan sebagai folder *cache*.

2. Berkas Fisik dan Struktur Direktori (*Input/Output Folder*)

Manajemen berkas fisik sepenuhnya memanfaatkan struktur folder lokal atau repositori *cloud drive* yang ditentukan sebagai parameter input.

(a) Folder/Drive Input

Berfungsi sebagai hulu data. Pengguna menempatkan seluruh kumpulan foto acak di dalam direktori ini. Sistem kemudian membaca foto secara sekuensial untuk mendeteksi wajah dan membangun *cache* vektor.

(b) Folder Hasil (*Output Folder*)

Untuk menyajikan hasil akhir, sistem tidak menduplikasi foto atau mengirimkannya ke media penyimpanan lain. Sistem akan secara otomatis membuat sebuah folder baru di dalam direktori *Folder/Drive Input*, misalnya */Hasil_Pencarian_Selfie/*. Foto target yang memiliki nilai kemiripan (*similarity score*) di atas ambang batas τ akan disalin (*copied*) atau dipindahkan secara terprogram ke dalam folder baru tersebut.


3. Perancangan Pemrosesan Berkelompok (*Chunk-Based Batching*)

Untuk menjembatani kelemahan konkurensi I/O dan meminimalkan overhead pemanggilan fungsi inferensi tensor, tahapan enkapsulasi ekstraksi embedding dirancang menggunakan metode batching dengan ukuran chunk konstan $B = 16$. Mekanisme ini mereduksi frekuensi instruksi level rendah runtime dari berbasis individual $\mathcal{O}(N)$ menjadi berkelompok $\mathcal{O}(\lceil \frac{N}{B} \rceil)$.

IV.4.3 Data Flow

Untuk memperjelas bagaimana data bertransformasi mulai dari foto mentah hingga menjadi hasil pencarian, bagian ini menjelaskan *data flow* sistem secara menyeluruh.

Diagram ini menyatukan alur *preprocessing* (Gambar IV.3) dan alur *query* (Gambar IV.4) ke dalam satu diagram yang menunjukkan pergerakan serta perubahan bentuk data di setiap komponen, mengikuti tiga lapisan arsitektur yang telah dijelaskan pada Bagian IV.4 (*Frontend Layer*, *Intelligence Layer*, dan *Data Layer*). Diagram *data flow* sistem ditunjukkan pada Gambar IV.6.



Gambar IV.6 Diagram *Data Flow* Sistem

Berdasarkan Gambar IV.6, pergerakan data pada sistem terbagi menjadi dua alur yang melalui tahap transformasi yang serupa sebelum akhirnya bertemu pada tahap pencocokan (*matching*).

1. Alur Pengindeksan (*Preprocessing*)

Data pada alur ini bermula dari *Folder Foto* yang dipilih pengguna sebagai masukan awal. Setiap foto yang dibaca akan melewati tahap deteksi wajah, sehingga menghasilkan data berupa koordinat *bounding box* beserta lima titik penanda (*keypoints*) wajah. Data tersebut digunakan pada tahap *alignment* untuk menghasilkan potongan citra wajah yang telah diselaraskan posisinya. Potongan wajah ini kemudian diproses oleh model *face representation*, sehingga diperoleh vektor fitur berdimensi 128 atau 512. Vektor tersebut dinormalisasi menggunakan *L2 Normalization* sehingga menjadi *unit vector*, sebelum akhirnya disimpan sebagai berkas JSON pada folder *cache* (*.face_cache/*), sesuai dengan mekanisme *Zero-DB Storage Architecture* yang telah dijelaskan pada Bagian IV.4.2.

2. Alur Pencarian (*Query*)

Data pada alur ini bermula dari 1 (satu) foto *selfie* yang dipilih pengguna sebagai kueri pencarian. Foto tersebut melewati tahap transformasi yang sama seperti alur pengindeksan, yaitu deteksi wajah, *alignment*, ekstraksi vektor

fitur, hingga normalisasi L2, sehingga dihasilkan satu *unit vector* yang merepresentasikan wajah kueri. Berbeda dengan alur pengindeksan, vektor pada alur ini tidak disimpan ke *cache* karena hanya digunakan sekali sebagai acuan pada tahap pencocokan.

3. Pencocokan (*Matching*) dan Penyaringan (*Filtering*)

Vektor kueri hasil alur pencarian dibandingkan dengan seluruh vektor yang tersimpan di dalam *cache* melalui perhitungan *Cosine Similarity*, sehingga setiap vektor target memperoleh skor kemiripan terhadap vektor kueri. Skor tersebut selanjutnya disaring berdasarkan nilai ambang batas yang ditentukan. Sehingga, hanya vektor dengan jarak kosinus di bawah nilai tersebut yang dinyatakan sebagai kecocokan (*match*).

4. Keluaran (*Output*)

Foto-foto yang dinyatakan cocok pada tahap penyaringan disalin ke dalam folder baru, yaitu Hasil_Pencarian_Selfie/, yang dibuat secara otomatis di dalam direktori *Folder Foto* masukan. Folder ini menjadi keluaran akhir yang dapat langsung diakses oleh pengguna.

Melalui diagram *data flow* ini, dapat terlihat bahwa seluruh transformasi data berlangsung secara *in-memory* tanpa keterlibatan basis data eksternal, sejalan dengan prinsip *Zero-DB Storage Architecture* yang menjadi salah satu batasan masalah dalam pengembangan sistem ini. Selain itu, alur pengindeksan pada dasarnya hanya perlu dijalankan sekali untuk setiap folder foto (dengan dukungan pengindeksan inkremental), sedangkan alur pencarian dapat dijalankan berulang kali dengan foto *selfie* yang berbeda tanpa perlu mengulang proses pengindeksan.

IV.5 Rencana Pengujian Sistem

Bagian ini akan menjelaskan mengenai rencana pengujian sistem yang akan dikembangkan. Bagian ini berisi penjelasan metode pengujian dan parameter keberhasilan yang digunakan.

IV.5.1 Metode Pengujian

Metode pengujian yang digunakan untuk menguji sistem yang dikembangkan memiliki dua tujuan, yaitu menguji fungsionalitas dan menguji performa. Berikut empat pengujian yang akan dilakukan pada tugas sistem yang dikembangkan di Tugas Akhir ini:

1. Pengujian Fungsional

Pengujian ini dilakukan untuk memastikan sistem dapat menerima *input* folder, memproses foto *selfie*, dan menghasilkan keluaran foto pribadi tanpa terjadi kegagalan sistem.

2. Pengujian Akurasi

Pengujian ini dilakukan untuk mengukur akurasi sistem dalam menyaring foto pribadi dengan membandingkannya pada *ground truth* yang ada.

3. Pengujian Performa

Pengujian ini dilakukan untuk menghitung waktu rata-rata yang dibutuhkan sistem untuk memproses masukan foto dari pengguna. Pengujian akan melibatkan variasi jumlah foto masukan (100, 300, 500, 700, dan 1000 foto) untuk mengevaluasi efisiensi sistem saat menangani volume data yang besar. Keluaran dari pengujian ini adalah grafik kinerja yang menunjukkan korelasi antara jumlah foto dengan durasi pemrosesan sistem.

4. Pengujian Stabilitas

Pengujian ini dilakukan untuk menguji ketahanan sistem dengan masukan yang rusak untuk memastikan sistem dapat tetap berjalan.

IV.5.2 Parameter Keberhasilan

Parameter keberhasilan diformulasikan dengan menurunkan dari non-fungsional *requirement*. Sistem dinyatakan berhasil jika memenuhi indikator yang ditunjukkan pada Tabel IV.2.

Tabel IV.2 Indikator Keberhasilan

No	Indikator Keberhasilan
1	Akurasi Minimal 85%: Hasil perhitungan <i>true positive</i> dan <i>true negative</i> harus menghasilkan skor akurasi di atas 85%. Angka ini menjadi batas toleransi agar sistem layak digunakan menggantikan pencarian manual.
2	Waktu Komputasi < 1 Detik per Tiga Identitas: Sistem harus mampu melakukan deteksi, ekstraksi fitur, dan pencocokan dengan kecepatan rata-rata di bawah 1 detik per tiga identitas pada <i>dataset</i> pengujian.
3	Skalabilitas Kapasitas: Sistem mampu memproses <i>dataset</i> yang besar foto dalam satu kali eksekusi (<i>batch processing</i>) tanpa mengalami kehabisan memori (<i>Out of Memory</i>).
4	Stabilitas Tanpa Crash: Sistem harus memiliki tingkat keberhasilan eksekusi 100% (tidak <i>force close</i>) meskipun terdapat <i>file</i> tidak valid atau foto tanpa wajah dalam <i>dataset input</i> .

IV.6 Gambaran Penggunaan Riil Sistem Usulan

Penggunaan riil sistem dapat digunakan untuk melakukan pencarian foto seseorang di suatu *event* atau kegiatan yang memiliki dokumentasi foto besar. Alur penggunaannya dapat dijabarkan sebagai berikut:

1. Tahap Penyiapan Masukan (*Input*)

Pengguna menentukan jalur direktori (*folder path*) penyimpanan yang berisi

kumpulan foto acak hasil dokumentasi kegiatan, yang disebut sebagai *Folder Input*. Selanjutnya, pengguna memilih 1 (satu) foto wajah dirinya sendiri atau foto selfie dari penyimpanan lokal sebagai acuan pencarian (*Foto Selfie / Query*).

2. Tahap Ekstraksi dan Pemrosesan Memori (*Processing*)

Aplikasi membaca seluruh citra di dalam *Folder Input* secara sekuensial. *AI Engine* secara otomatis mendeteksi wajah, melakukan penyelarasan posisi (*alignment*), dan mengonversinya menjadi representasi numerik ringkas berupa vektor fitur yang disimpan sementara di dalam direktori sebagai *cache*.

3. Tahap Pencocokan (*Matching*)

AI Engine menghitung skor kemiripan (*similarity score*) menggunakan operasi perkalian matriks antara vektor *Foto Selfie* dengan seluruh vektor target yang tersimpan di dalam *cache* memori.

4. Tahap Penyajian Hasil (*Output*)

Sistem menyaring foto-foto yang memiliki nilai kemiripan di atas ambang batas (*threshold*). Secara otomatis, sistem akan membuat sebuah folder baru di dalam direktori *Folder Input*, misalnya */Hasil_Pencarian/*, kemudian menyalin file foto yang cocok ke dalam folder tersebut. Pengguna dapat langsung melihat hasil pengelompokan foto pribadinya di dalam penyimpanan lokal.

BAB V

IMPLEMENTASI

V.1 Lingkungan Implementasi

Sistem pencarian foto pribadi otomatis ini diimplementasikan sepenuhnya menggunakan bahasa pemrograman Python sebagai fondasi utama. Implementasi dibagi menjadi dua fase: fase eksplorasi algoritma (membandingkan berbagai pendekatan *face recognition*) dan fase implementasi sistem produksi (membangun aplikasi desktop *offline* berbasis komponen terbaik hasil eksplorasi).

Berikut adalah spesifikasi komponen teknologi yang digunakan:

1. **Bahasa Pemrograman**

Python 3.10+ sebagai versi standar yang digunakan.

2. **Fase Eksplorasi Algoritma (*Exploration*)**

DeepFace digunakan sebagai antarmuka unifikasi berbagai model *face recognition* berbasis TensorFlow/Keras. Pustaka ini memungkinkan perbandingan yang adil (*fair benchmark*) antar berbagai algoritma representasi wajah pada lingkungan yang beragam.

Kode eksplorasi dijalankan di *notebook* untuk mempermudah analisis dengan menambahkan visualisasi terkait hasil dari perbandingan.

3. **Fase Produksi (*AI Engine*)**

- (a) *ONNX Runtime*

Mesin inferensi ringan berbasis C++ untuk model ArcFace dan detektor SCRFD yang berjalan di *ONNX runtime*.

- (b) *Google Cloud Project*

Digunakan untuk integrasi ke Google Drive sebagai folder masukan dengan OAuth 2.0 untuk autentikasi Google Drive API.

- (c) *CustomTkinter*

Kerangka kerja antarmuka pengguna grafis (*GUI*).

4. **Pustaka Pemrosesan Data & Citra**

OpenCV (ekstraksi matriks citra dan transformasi afin), *NumPy* (manipulasi

array vektor berdimensi tinggi), dan *Pillow* (manajemen format berkas gambar)

Berikut adalah algoritma *face recognition* yang dibandingkan:

1. **Metode Berbasis Geometri (*Geometry-Based Methods*)**
 - (a) *Geometry-Based Method*
2. **Metode Holistik (*Holistic Methods*)**
 - (a) *PCA*
3. **Metode Berbasis Fitur (*Feature-Based Methods*)**
 - (a) *LBP*
 - (b) *HOG*
4. **Metode Hibrida (*Hybrid Methods*)**
 - (a) *LBP + PCA*
5. **Metode Pembelajaran Mendalam (*Deep Learning Methods*)**
 - (a) *DeepFace (FaceNet)*
 - (b) *DeepFace (VGG-Face)*
 - (c) *DeepFace (ArcFace)*


V.2 Analisis Perbandingan Algoritma

Eksplorasi eksperimental dilakukan dengan menguji delapan model representasi wajah dari lima kategori yang telah didefinisikan pada rencana perancangan (Bab IV), dikombinasikan dengan dua detektor wajah: MTCNN dan SCRFD (*Sample and Computation Redistribution Face Detector*). Pengujian dilakukan secara adil (*fair benchmark*) menggunakan lingkungan perangkat keras yang sama, dengan total dataset uji sebesar 1.000 foto target dan 1 foto kueri *selfie* sebagai acuan identitas. Hasil lengkap seluruh kombinasi disajikan pada Tabel V.1.

V.2.1 Perbandingan F1-Score

Gambar V.1 dan Gambar V.2 menunjukkan bahwa metode berbasis *deep learning* secara konsisten mendominasi peringkat F1-Score pada kedua konfigurasi detektor. Pada detektor MTCNN, tiga model teratas adalah *VGG-Face* (0,747), *FaceNet* (0,735), dan *ArcFace* (0,711), jauh melampaui metode tradisional seperti HOG (0,471) dan PCA (0,451).

Penggunaan detektor SCRFD secara keseluruhan meningkatkan F1-Score seluruh model: *VGG-Face* melonjak menjadi 0,819, *FaceNet* menjadi 0,763, dan *ArcFace* menjadi 0,755. Peningkatan ini mengindikasikan bahwa kualitas *crop* wajah yang dihasilkan SCRFD lebih optimal sebagai masukan komponen *embedding*, berkat presisi deteksi *anchor-free* yang lebih akurat.




Gambar V.1 Perbandingan F1-Score Seluruh Model dengan Detektor MTCNN

V.2.2 Evaluasi Waktu Komputasi

Waktu deteksi MTCNN untuk 1.000 foto mencapai 322,40 detik, sedangkan SCRFD menyelesaikan tugas yang sama dalam 141,33 detik dengan percepatan sebesar $\pm 2,3 \times$. Komponen ekstraksi fitur mendominasi total waktu pemrosesan pada metode *deep learning*: *ArcFace* membutuhkan sekitar 1.243 detik (MTCNN) dan 1.524 detik (SCRFD) untuk mengekstrak *embedding* dari 1.000 foto via *backend* DeepFace/TensorFlow.

Meskipun demikian, ekstraksi fitur merupakan *one-time cost* yang hasilnya disimpan dalam *cache* JSON, sehingga sesi pencarian berikutnya tidak memerlukan ekstraksi ulang. Metode tradisional (Geometri, LBP, HOG, PCA) memiliki waktu ekstraksi fitur yang jauh lebih singkat (di bawah 25 detik untuk 1.000 foto), namun nilai F1-Score yang rendah menjadikannya tidak memenuhi syarat minimal akurasi sistem.




Gambar V.2 Perbandingan F1-Score Seluruh Model dengan Detektor SCRFD

V.2.3 Evaluasi Penggunaan Memori

Kolom *Memory Usage* pada Tabel V.1 mencerminkan konsumsi memori inkremental komponen representasi wajah saat memproses 1.000 foto. *ArcFace* dan *FaceNet* menunjukkan konsumsi memori inkremental mendekati nol (0,000 MB), karena representasi *embedding* 512 dimensi berformat `float32` hanya memerlukan ≈ 2 KB per wajah. Sebaliknya, *VGG-Face* mengonsumsi memori inkremental yang sangat besar: 534,73 MB (MTCNN) dan 1.825,36 MB (SCRFD), akibat alokasi *buffer intermediate activation* TensorFlow yang proporsional terhadap arsitektur model yang lebih dalam. Lonjakan drastis pada konfigurasi SCRFD menunjukkan bahwa resolusi *crop* yang lebih tinggi dari SCRFD memperbesar alokasi tensor internal VGG-Face secara signifikan.

V.2.4 Hasil Perbandingan Lengkap

Tabel V.1 merangkum seluruh metrik evaluasi dari delapan model pada kedua konfigurasi detektor. Secara umum, detektor SCRFD menghasilkan performa yang lebih baik hampir pada semua model dibandingkan MTCNN, baik dari sisi akurasi, F1-



Gambar V.3 Perbandingan Waktu Komputasi Seluruh Model dengan Detektor MTCNN

Score, maupun kecepatan deteksi, sehingga SCRFD menjadi kandidat detektor yang lebih unggul untuk sistem produksi.


V.3 Algoritma yang Dipilih

Berdasarkan hasil analisis komparatif di atas, **ArcFace** dipilih sebagai algoritma representasi wajah dan **SCRFD** dipilih sebagai detektor wajah pada sistem produksi. Pemilihan ini didasarkan pada argumen berikut:

1. Keseimbangan Optimal antara Akurasi dan Efisiensi Memori

Dengan detektor SCRFD, *ArcFace* mencapai akurasi 89,1% dan F1-Score 0,755, sehingga memenuhi indikator keberhasilan nonfungsional minimal 85% pada Tabel III.2. *VGG-Face* memang menghasilkan akurasi lebih tinggi (92,2%) dan F1-Score 0,819, namun disertai konsumsi memori inkremental sebesar 1.825,36 MB, lebih dari $400\times$ lebih besar dibandingkan *ArcFace*. Untuk konteks aplikasi *desktop offline* yang menargetkan perangkat dengan sumber daya terbatas, beban memori sebesar itu tidak dapat diterima.

2. Keunggulan Arsitektur *Additive Angular Margin Loss*




Gambar V.4 Perbandingan Waktu Komputasi Seluruh Model dengan Detektor SCRFD

Keunggulan utama *ArcFace* terletak pada fungsi ruginya yang mendistribusikan *face embedding* berdasarkan margin sudut (*angular margin*) di ruang hiperbolik. Mekanisme ini menghasilkan representasi fitur yang lebih diskriminatif dibandingkan metode berbasis *softmax* konvensional, sehingga lebih tangguh terhadap variasi pencahayaan, pose *candid*, dan kondisi wajah tertutup sebagian pada foto dokumentasi riil.

3. Kompatibilitas ONNX Runtime

Model *ArcFace* tersedia dalam format ONNX (`w600k_r50.onnx`), memungkinkan inferensi langsung melalui ONNX Runtime tanpa ketergantungan pada TensorFlow. Migrasi ini menghasilkan peningkatan kecepatan inferensi *embedding* sebesar $\pm 10\text{--}15\times$ (dari 0,15–0,25 detik menjadi 0,008–0,020 detik per wajah) dan mengurangi waktu inisialisasi model dari 5–15 detik menjadi kurang dari 1 detik.

Argumen pemilihan SCRFD didasarkan pada kecepatan deteksi yang $\pm 2,3\times$ lebih cepat dibandingkan MTCNN (141,33 detik vs 322,40 detik untuk 1.000 foto), kualitas *landmark* 5 titik yang setara, serta konsistensi *backend*. SCRFD juga tersedia da-



Gambar V.5 Perbandingan Penggunaan Memori Seluruh Model dengan Detektor MTCNN


lam format ONNX (det_2.5g.onnx) sehingga sistem produksi cukup bergantung pada satu mesin inferensi tunggal.

Dengan demikian, sistem produksi mengintegrasikan kombinasi komponen berikut:

1. **SCRFD** (det_2.5g.onnx) sebagai komponen deteksi wajah
2. **ArcFace ResNet-50** (w600k_r50.onnx) sebagai komponen ekstraksi *embedding* 512 dimensi
3. **ONNX Runtime** (CPUExecutionProvider) sebagai mesin inferensi untuk kedua model di atas

V.4 Implementasi Sistem Produksi

Sistem produksi diimplementasikan sebagai aplikasi desktop *offline* sepenuhnya. Seluruh inferensi model, manajemen *cache*, dan penyalinan hasil dilakukan secara lokal di perangkat pengguna.



Gambar V.6 Perbandingan Penggunaan Memori Seluruh Model dengan Detektor SCRFD

V.4.1 Arsitektur Komponen Perangkat Lunak

Sistem diorganisasi ke dalam tiga lapisan komponen:

1. **Lapisan GUI** (`src/gui/`): Antarmuka pengguna berbasis CustomTkinter dengan dua mode: mode produksi (`main.py`, *threshold* tetap $\tau = 0,60$) dan mode demonstrasi (`main_demo.py`, *threshold* dapat diatur melalui *slider* 0,10–1,00, dilengkapi pelaporan metrik evaluasi). Kelas `DemoApp` mewarisi (*inherits*) dari `MainApp` dan hanya menimpa (*overrides*) komponen yang berbeda.
2. **Lapisan Inti** (`src/core/`): Tiga komponen *stateless* yang dapat digunakan secara independen:
 - (a) `FaceDetector`
Deteksi wajah dengan SCRFD atau MTCNN, dilengkapi *fallback* resolusi progresif (960px → 720px → 512px → 360px) untuk menangani gambar beresolusi sangat tinggi
 - (b) `ArcFaceONNXRunner`
Ekstraksi *embedding* 512 dimensi via ONNX Runtime, mendukung *ba-*

tch inference

(c) FaceMatcher

Pencarian jarak kosinus tervektor menggunakan operasi perkalian matriks NumPy (`np.dot`)

3. **Lapisan Data** (`src/cache_io/`, `src/utils/`): CacheHandler mengelola *cache* JSON per-wajah di direktori `.face_cache/`; FileManager mengelola pemindaian folder rekursif (mengecualikan `.face_cache/` dan `Hasil_Pencarian_Selfie/`) dan penyalinan hasil.

V.4.2 Pemrosesan Latar Belakang dan *Thread Safety*

Operasi pengindeksan dan pencarian dijalankan di *daemon thread* terpisah (PipelineWorker dan SearchWorker) agar antarmuka GUI tetap responsif selama pemrosesan berlangsung. Semua pembaruan *widget* dari *thread* latar belakang dilakukan melalui `root.after(0, callback)`, yang menjadwalkan *callback* pada iterasi berikutnya dari *event loop* Tkinter di *thread* utama.

V.4.3 Pengindeksan Inkremental dan Pemrosesan *Chunk*

Sistem mendukung pengindeksan inkremental: foto yang telah memiliki entri *cache* dilewati secara otomatis pada sesi pengindeksan berikutnya. Kunci *cache* berupa MD5 dari pasangan (*nama_file_relatif*, *bounding box*), sehingga bersifat *location-agnostic* karena pemindahan folder tidak membatalkan *cache*.

Foto baru diproses dalam kelompok (*chunk*) berukuran $B = 16$ foto. Untuk setiap *chunk*:

1. Deteksi wajah dijalankan secara sekuensial untuk 16 foto
2. Seluruh *crop* wajah dari 16 foto dikumpulkan menjadi satu *batch tensor* berukuran $(N_{\text{wajah}}, 3, 112, 112)$
3. Satu pemanggilan `session.run()` mengekstrak *embedding* untuk seluruh *batch*
4. Setiap *embedding* disimpan ke *cache* JSON segera setelah diekstrak

Mekanisme ini mereduksi frekuensi pemanggilan `session.run()` dari $\mathcal{O}(N)$ menjadi $\mathcal{O}(\lceil \frac{N}{B} \rceil)$, yang secara signifikan mengurangi *overhead* eksekusi ONNX Runtime.

Tabel V.1 Hasil Perbandingan Lengkap (8 Model) dengan Detektor MTCNN dan SCRFD

Tabel 1. Hasil Perbandingan dengan Detektor MTCNN

Model	Accuracy	Precision	Recall	F1-Score	Best Threshold	Feature Extraction Time (s)	Inference Time (s)	Memory Usage (MB)	Detection Time (s)
Geometry-Based	0.345000	0.259557	0.960396	0.408667	0.05	1.794549	6.875577	0.796875	322.398885
PCA (Holistik)	0.547667	0.315760	0.787836	0.450830	0.95	3.439454	7.505657	284.753906	322.398885
LBP (Berbasis Fitur)	0.441333	0.280868	0.878359	0.425634	0.25	11.494441	7.472873	0.781250	322.398885
HOG (Berbasis Fitur)	0.574000	0.332748	0.803395	0.470588	0.30	18.239864	8.448654	132.109375	322.398885
LBP + PCA (Hibrida)	0.459333	0.276284	0.799151	0.410610	0.95	11.062305	7.749343	412.812500	322.398885
DeepFace (Face-net)	0.874333	0.730447	0.739745	0.735067	0.40	1607.450316	8.306349	0.000000	322.398885
DeepFace (VGG-Face)	0.894333	0.858456	0.660537	0.746603	0.60	1743.119371	9.228585	534.734375	322.398885
DeepFace (ArcFace)	0.861000	0.696477	0.727016	0.711419	0.65	1243.435217	11.005755	0.000000	322.398885

Tabel 2. Hasil Perbandingan dengan Detektor SCRFD

Model	Accuracy	Precision	Recall	F1-Score	Best Threshold	Feature Extraction Time (s)	Inference Time (s)	Memory Usage (MB)	Detection Time (s)
Geometry-Based	0.290000	0.249207	1.000000	0.398984	0.05	2.854128	10.009302	0.945312	141.329536
PCA (Holistik)	0.514333	0.308282	0.852900	0.452873	0.95	5.522211	10.739054	417.066406	141.329536
LBP (Berbasis Fitur)	0.372000	0.267850	0.960396	0.418877	0.30	15.818657	9.571036	0.203125	141.329536
HOG (Berbasis Fitur)	0.587667	0.336015	0.768034	0.467499	0.30	24.706835	9.894295	164.617188	141.329536
LBP + PCA (Hibrida)	0.408000	0.262550	0.835926	0.399594	0.95	14.041398	10.164680	375.601562	141.329536
DeepFace (Face-net)	0.889000	0.767908	0.758133	0.762989	0.40	1761.458499	12.435488	0.000000	141.329536
DeepFace (VGG-Face)	0.922000	0.905660	0.746818	0.818605	0.60	2147.132272	13.597491	1825.359375	141.329536
DeepFace (ArcFace)	0.891000	0.803514	0.711457	0.754689	0.60	1524.226980	11.120317	0.000000	141.329536

BAB VI

EVALUASI

VI.1 Metode Evaluasi

Pengujian sistem dilakukan sesuai dengan rencana yang telah ditetapkan pada Bab IV, meliputi empat jenis pengujian: fungsional, akurasi, performa, dan stabilitas.

VI.1.1 Pengujian Fungsional

Pengujian fungsional dilakukan dengan menjalankan sistem menggunakan dataset foto riil dan memverifikasi bahwa seluruh alur kerja berjalan tanpa kegagalan. Kriteria keberhasilan mencakup: (1) sistem berhasil menerima masukan berupa direktori folder foto (FR1), (2) sistem berhasil mengidentifikasi foto yang mengandung wajah kueri (FR2), dan (3) sistem menghasilkan folder keluaran Hasil_Pencarian_Selfie/ berisi foto-foto hasil penyaringan (FR3).

VI.1.2 Pengujian Akurasi

Pengujian akurasi dilakukan menggunakan mode demonstrasi sistem (*Demo Mode*) yang memanfaatkan berkas *ground truth* (GT) dalam format JSON. Berkas GT memiliki struktur *multi-person* yang mendefinisikan keberadaan setiap orang uji pada setiap foto dataset:

```
1 {  
2   "0001.jpg": {  
3     "contains_person_A": true,  
4     "contains_person_B": false,  
5     "contains_person_C": false  
6   },  
7   "0022.jpg": {  
8     "contains_person_A": true,  
9     "contains_person_B": true,  
10    "contains_person_C": false  
11  }  
12 }
```

Listing VI.1 Contoh Format Berkas *Ground Truth* JSON

Evaluasi dilakukan per-kueri (satu pencarian per orang). Hasil pencarian dibandingkan dengan kolom GT yang relevan untuk menghasilkan *confusion matrix*: *True Positive* (TP), *False Positive* (FP), *False Negative* (FN), dan *True Negative* (TN). Metrik evaluasi diturunkan dari *confusion matrix* tersebut:

$$\text{Precision} = \frac{TP}{TP + FP} \quad (\text{VI.1})$$

$$\text{Recall} = \frac{TP}{TP + FN} \quad (\text{VI.2})$$

$$F_1 = \frac{2 \times \text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} \quad (\text{VI.3})$$

$$\text{Accuracy} = \frac{TP + TN}{N_{\text{total}}} \quad (\text{VI.4})$$

Nilai *threshold* yang digunakan adalah $\tau = 0,60$, yang dipilih melalui pencarian kisi (*grid search*) dengan rentang $\tau \in \{0,05, 0,10, \dots, 0,95\}$ untuk memaksimalkan F_1 -score pada data *ground truth* tiga orang uji.

VI.1.3 Pengujian Performa

Pengujian performa dilakukan dengan mengukur waktu komputasi setiap tahap *pipeline* menggunakan `time.perf_counter()`. Tahap yang diukur meliputi *face detection* (inferensi SCRFD), *face alignment* (transformasi afin), dan *feature extraction* (inferensi *batch* ArcFace ONNX). Pengujian dilakukan terhadap dataset yang bervariasi (100, 300, 500, 700, dan 1.000 foto) untuk menganalisis skalabilitas sistem.

VI.1.4 Pengujian Stabilitas

Pengujian stabilitas dilakukan dengan menyisipkan berkas foto yang rusak (*corrupt*) ke dalam dataset pengujian. Sistem dinyatakan lulus apabila dapat melanjutkan pemrosesan foto berikutnya tanpa terminasi serta berhasil menerapkan mekanisme *fall-back* resolusi progresif untuk foto berukuran sangat besar.

VI.2 Hasil Evaluasi

VI.2.1 Hasil Pengujian Fungsional

Sistem berhasil menyelesaikan seluruh skenario pengujian fungsional yang ditetapkan. Sistem mampu membaca folder masukan secara rekursif (termasuk subfolder),

mendeteksi dan mengekstrak *embedding* wajah dari setiap foto, menyimpan hasil ke *cache* JSON, serta menyalin foto yang cocok ke folder Hasil_Pencarian_Selfie/. Pengindeksan bersifat inkremental dengan foto yang telah diindeks pada sesi sebelumnya tidak diproses ulang, yang diverifikasi dengan menjalankan pengindeksan dua kali pada folder yang sama dan memastikan tidak ada foto yang diproses ulang pada sesi kedua.

VI.2.2 Hasil Pengujian Akurasi

Pengujian akurasi dilakukan pada dataset 1.000 foto dengan 3 orang uji (Person A, B, C). Hasil pencarian pada *threshold* optimal $\tau = 0,60$ menghasilkan akurasi sistem sebesar 96,8%.

Tabel VI.1 menunjukkan pengaruh variasi nilai *threshold* terhadap perilaku sistem:

Tabel VI.1 Pengaruh Nilai *Threshold* terhadap Perilaku Sistem

<i>Threshold</i> (τ)	Precision	Recall	F_1-Score
0,40	Sangat Tinggi	Rendah	Sedang
0,50	Tinggi	Sedang	Tinggi
0,60	Tinggi	Tinggi	Tertinggi
0,70	Sedang	Sangat Tinggi	Sedang-Tinggi
0,80	Rendah	Sangat Tinggi	Sedang

Pada *threshold* rendah ($\tau < 0,50$), sistem bersifat terlalu selektif sehingga banyak foto yang seharusnya dikembalikan tidak dikembalikan (*false negative* tinggi, *recall* rendah). Sebaliknya, pada *threshold* tinggi ($\tau > 0,70$), sistem bersifat terlalu longgar sehingga banyak foto yang seharusnya tidak dikembalikan ikut dikembalikan (*false positive* tinggi, *precision* rendah). Nilai $\tau = 0,60$ memberikan keseimbangan optimal antara *Precision* dan *Recall*, menghasilkan F_1 -score tertinggi.

VI.2.3 Hasil Pengujian Performa

Tabel VI.2 merangkum hasil pengukuran waktu komputasi *pipeline* sistem terhadap 1.000 foto (total ± 7.843 wajah terdeteksi):

Tabel VI.2 Hasil Pengukuran Waktu Komputasi *Pipeline* (1.000 Foto)

Tahap	Waktu per Satuan	Total
<i>Face Detection</i> (SCRFD)	$\pm 0,077$ detik/foto	± 77 detik
<i>Face Alignment</i> (afin)	$\pm 0,001$ detik/wajah	< 10 detik
<i>Feature Extraction</i> (ArcFace ONNX, <i>batch</i> 16)	$\pm 0,075$ detik/ <i>batch</i>	± 30 detik
<i>Cache I/O</i> (JSON)	$\pm 0,001$ detik/wajah	± 8 detik
<i>Search</i> (kosinus, ± 7.843 <i>embedding</i>)	$< 0,1$ detik	
Total Indexing Pipeline	-	$\pm 115\text{--}125$ detik

Kecepatan rata-rata keseluruhan sistem adalah sekitar 0,115–0,125 detik per foto, jauh di bawah batas yang ditetapkan dalam parameter keberhasilan (< 1 detik per foto). Fase pencarian (*search*) selesai dalam waktu kurang dari 0,1 detik untuk ± 7.843 *embedding* karena menggunakan operasi perkalian matriks tervektor (np.dot) yang memanfaatkan instruksi SIMD CPU.

VI.2.4 Hasil Pengujian Stabilitas

Sistem berhasil mempertahankan keberlangsungan pemrosesan saat menghadapi berkas foto yang rusak. Foto yang tidak dapat dibaca oleh OpenCV dilewati secara senyap (*silently skipped*) tanpa menghentikan proses pengindeksan. Mekanisme *fallback* resolusi progresif juga berjalan dengan benar, foto yang beresolusi sangat tinggi ($> 1.080\text{px}$) diproses pada resolusi yang direduksi secara bertahap ($960\text{px} \rightarrow 720\text{px} \rightarrow 512\text{px} \rightarrow 360\text{px}$), dengan koordinat *bounding box* dan *keypoint* yang diskalakan kembali ke ruang koordinat gambar asli sebelum dilakukan *alignment*.

VI.3 Pembahasan Hasil Evaluasi

VI.3.1 Pemenuhan Parameter Keberhasilan

Berdasarkan hasil evaluasi yang telah dilakukan, seluruh parameter keberhasilan yang ditetapkan pada Bab IV terpenuhi:

1. **Akurasi** $\geq 85\%$: Sistem mencapai akurasi 96,8%, melampaui batas minimal sebesar 11,8 poin persentase.
2. **Waktu Komputasi** < 1 detik per foto: Sistem mencapai rata-rata $\pm 0,115$

detik per foto (mencakup deteksi, *alignment*, dan ekstraksi fitur), yaitu $\pm 8,7 \times$ lebih cepat dari batas yang ditetapkan.

3. **Keberlangsungan pada Masukan Rusak:** Sistem berhasil mempertahankan pemrosesan saat menghadapi foto yang rusak maupun foto beresolusi sangat tinggi yang dapat menyebabkan *out-of-memory*.

VI.3.2 Analisis Pengaruh Optimasi ONNX Runtime

Peningkatan performa yang signifikan antara fase eksplorasi (berbasis *DeepFace*/TensorFlow, $\pm 0,42$ detik per foto) dan sistem produksi ($\pm 0,115$ detik per foto) disebabkan oleh dua faktor utama:

1. **Efisiensi *Backend* ONNX Runtime:** ONNX Runtime menjalankan graf komputasi yang telah dioptimalkan secara langsung dalam *runtime* C++ tanpa *overhead* inisialisasi TensorFlow. Waktu inferensi per wajah turun dari 0,15–0,25 detik (*DeepFace*) menjadi 0,008–0,020 detik (ONNX), peningkatan sebesar ± 10 – $15 \times$.
2. **Inferensi *Batch*:** Pemrosesan dalam *chunk* 16 foto per pemanggilan `session.run()` mereduksi *overhead* eksekusi ONNX dari $\mathcal{O}(N)$ menjadi $\mathcal{O}(\lceil \frac{N}{16} \rceil)$. Untuk 1.000 foto dengan rata-rata $\pm 7,8$ wajah per foto, jumlah pemanggilan `session.run()` turun dari ± 7.800 menjadi ± 490 .

VI.3.3 Keterbatasan Sistem yang Teridentifikasi

Berdasarkan hasil evaluasi, terdapat beberapa keterbatasan sistem yang perlu diperhatikan:

1. **Sensitivitas terhadap Kualitas Foto Kueri:** Akurasi pencarian sangat bergantung pada kualitas foto *selfie* yang digunakan sebagai kueri. Foto dari sudut samping, resolusi sangat rendah, atau dengan oklusi (kacamata, masker wajah) dapat meningkatkan tingkat *false negative*.
2. **Kueri Tunggal per Sesi:** Sistem hanya mendukung satu foto *selfie* sebagai kueri per sesi pencarian. Tidak tersedia mekanisme penggabungan beberapa foto kueri menjadi satu representasi *embedding* yang lebih kuat.
3. **Format Berkas Terbatas:** Pemindai berkas hanya mengenali ekstensi `.jpg`, `.jpeg`, dan `.png`. Format lain seperti `.heic` dan `.webp` tidak didukung pada versi ini.
4. **Invalidasi *Cache* Manual:** Sistem tidak mendeteksi perubahan pada foto yang telah diindeks. Apabila foto dimodifikasi setelah diindeks, pengguna harus menghapus direktori `.face_cache/` dan menjalankan ulang pengindeksan untuk memperbarui entri *cache*.

BAB VII

PENUTUP

VII.1 Kesimpulan

Jelaskan secara detail langkah-langkah rencana selanjutnya, hal-hal yang diperlukan atau akan disiapkan, dan risiko dan mitigasinya, yang meliputi:

VII.2 Saran

asdfas

DAFTAR PUSTAKA

- Ahonen, Timo, Abdenour Hadid, dan Matti Pietikainen. 2006. "Face Description with Local Binary Patterns: Application to Face Recognition", 28:2037–2041. 12. <https://doi.org/10.1109/TPAMI.2006.244>.
- Albayati, Arkan Mahmood. 2024. "One-Shot Learning for Face Recognition Using Deep Learning: A Survey". *International Journal of Intelligent Systems and Applications in Engineering* 12 (4): 2473–. <https://ijisae.org/index.php/IJISAE/article/view/6676>.
- Albiol, Alberto, David Monzo, Antoine Martin, Jorge Sastre, dan Antonio Albiol. 2008. "Face Recognition Using HOG–EBGM". *Pattern Recognition Letters* 29 (10): 1537–1543. <https://doi.org/10.1016/j.patrec.2008.03.017>.
- Belhumeur, Peter, Joao Hespanha, dan David Kriegman. 1997. "Eigenfaces vs. Fisherfaces: Recognition Using Class Specific Linear Projection". *IEEE Trans. Pattern Anal. Mach. Intell.* 19:711–720. <https://doi.org/10.1109/34.598228>.
- Brunelli, Roberto, dan Tomaso Poggio. 1993. "Face Recognition: Features versus Templates". *IEEE Transactions on Pattern Analysis and Machine Intelligence* 15 (10): 1042–1052. <https://doi.org/10.1109/34.254061>.
- Dalal, Navneet, dan Bill Triggs. 2005. "Histograms of Oriented Gradients for Human Detection". Dalam *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 1:886–893. <https://doi.org/10.1109/CVPR.2005.177>.
- Deng, Jiankang, Jia Guo, Niannan Xue, dan Stefanos Zafeiriou. 2019. "ArcFace: Additive Angular Margin Loss for Deep Face Recognition". Dalam *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 4690–4699. <https://doi.org/10.1109/CVPR.2019.00482>.

- Fortune Business Insights. 2025. *Cloud Storage Market Size, Share & Industry Analysis, By Type (Private; Public; Hybrid), By Component (Storage Model: Object Storage; File Storage; Block Storage; Services), By Enterprise Type (SMEs; Large Enterprises), By Vertical (BFSI; IT & Telecommunication; Government & Public Sector; Manufacturing; Healthcare & Life Sciences; Retail & Consumer Goods; Media & Entertainment; Others), and Regional Forecast, 2025-2032 (Report ID FBI102773)*. Accessed 2025-10-22. Fortune Business Insights. <https://www.fortunebusinessinsights.com/cloud-storage-market-102773>.
- Guo, Jia, Jiankang Deng, Alexandros Lattas, dan Stefanos Zafeiriou. 2021. "Sample and Computation Redistribution for Efficient Face Detection". *arXiv preprint arXiv:2105.04714*, arXiv: 2105.04714 [cs.CV].
- Li, Jingwen, Yanting Cai, Xu Gong, Jiang Wu, Yanling Lu, Xiaode Meng, dan Li Zhang. 2023. "Semantic Retrieval of Remote Sensing Images Based on the Bag-of-Words Association Mapping Method". *Sensors* 23:5807. <https://doi.org/10.3390/s23135807>.
- Parkhi, Omkar M., Andrea Vedaldi, dan Andrew Zisserman. 2015. "Deep Face Recognition". Dalam *Proceedings of the British Machine Vision Conference (BMVC)*. <https://doi.org/10.5244/C.29.41>.
- Qazanfari, Hamed, Mohammad M. AlyanNezhadi, dan Zohreh Nozari Khoshdaregi. 2023. *Advancements in Content-Based Image Retrieval: A Comprehensive Survey of Relevance Feedback Techniques*. arXiv: 2312.10089 [cs.CV]. <https://arxiv.org/abs/2312.10089>.
- Schroff, Florian, Dmitry Kalenichenko, dan James Philbin. 2015. "FaceNet: A Unified Embedding for Face Recognition and Clustering". Dalam *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 815–823. <https://doi.org/10.1109/CVPR.2015.7298682>.
- The Business Research Company. 2025. *Digital Photography Global Market Report 2025: By Type (Photo Processing Equipment; Interchangeable Lenses; Camera Cell Phones; Other Types), By Application (Photography Software; Photo Looks; Photo Processing; Other Applications), By Distribution Channel (Online; Offline), By End-User (Personal; Profession) – Impact of Tariff and Trade War on Market Size, Growth, Trends, and Forecast 2025-2034*. Accessed 2025-10-22. The Business Research Company. <https://www.thebusinessresearchcompany.com/report/digital-photography-global-market-report>.

- Trigueros, Daniel Sáez, Li Meng, dan Margaret Hartnett. 2018. “Face Recognition: From Traditional to Deep Learning Methods”, <https://doi.org/10.48550/ARXIV.1811.00116>. <https://arxiv.org/abs/1811.00116>.
- Wang, Mei, dan Weihong Deng. 2021. “Deep Face Recognition: A Survey”. *Neurocomputing* 429:215–244. <https://doi.org/10.1016/j.neucom.2020.10.081>.
- Zhang, Kaipeng, Zhanpeng Zhang, Zhifeng Li, dan Yu Qiao. 2016. “Joint Face Detection and Alignment Using Multitask Cascaded Convolutional Networks”. *IEEE Signal Processing Letters* 23 (10): 1499–1503. <https://doi.org/10.1109/LSP.2016.2603342>.
- Zhao, Wen-Yi, Rama Chellappa, P. Jonathon Phillips, dan Azriel Rosenfeld. 2003. “Face Recognition: A Literature Survey”. *ACM Comput. Surv.* 35:399–458. <https://doi.org/10.1145/954339.954342>.

LAMPIRAN A

KODE PROGRAM

Pada umumnya, kode program tidak perlu disertakan di dalam laporan tugas akhir karena kode program biasanya sangat panjang dan sudah disimpan dalam bentuk berkas-berkas elektronik terpisah di repositori daring. Namun, jika ada bagian kode program singkat yang penting untuk ditulis dalam laporan tugas akhir, bagian tersebut dapat disertakan di dalam laporan.

A.1 Perangkat Lunak untuk Akuisisi Data dari Sensor Ultrasonik

```
1 % -- Example of pseudocode and source code listing --
2 % -- Gunakan minipage agar listing tidak terpotong ke halaman
   berikutnya --
3
4
5
6 \begin{minipage}{\textwidth}
7 \begin{lstlisting}[caption={Iterative binary search in Python},
   label={lst:binary_iter}, frame=single, captionpos=t, language=
   Python]
8 def binary_search(arr, target):
9     """
10     Performs binary search on a sorted array.
11
12     Args:
13         arr: A sorted list of elements
14         target: The element to search for
15
16     Returns:
17         Index of target if found, -1 otherwise
18     """
19     left = 0
20     right = len(arr) - 1
21
22     while left <= right:
23         mid = (left + right) // 2
24
```

```

25     if arr[mid] == target:
26         return mid
27     elif arr[mid] < target:
28         left = mid + 1
29     else:
30         right = mid - 1
31
32     return -1
33
34
35 \end{lstlisting}
36 \end{minipage}

```

Listing A.1 Binary search code

A.2 Perangkat Lunak untuk Pengolahan Data Akuisisi dan Visualisasi Hasil Pengukuran Jarak

asdjfkjashdkjfas

LAMPIRAN B

HASIL SURVEI LAPANGAN

B.1 Foto Survei Lokasi 1

Teks survei lokasi 1.

B.2 Foto Survei Lokasi 2

Teks survei lokasi 2.

B.3 Transkrip Wawancara dengan Narasumber

Teks transkrip wawancara.

